

卒業論文

オープンセット環境下における  
レーダ心拍信号を用いた深層学習  
による人物識別

慶應義塾大学理工学部情報工学科

大槻研究室

学籍番号 61908013

権 藤 陸

指導教員：大槻知明 教授

提出 令和5年2月3日

## 卒業論文概要 2023 年度（令和 5 年度）

# オープンセット環境下におけるレーダ心拍信号を用いた深層学習による人物識別

テンプレートの説明を，テンプレート自身を使って説明する．これは卒業論文のための L<sup>A</sup>T<sub>E</sub>X テンプレートで，本当は卒業論文のために作成したものだけどでもたぶんきっと修士論文にも使えると思う．

この部分には一般には論文のアブストラクトを書く．日本語のアブストラクトを書きたいなら，`\begin{jabstract}` と `\end{jabstract}` の間に文章を書けば，今のこのページのように体裁が勝手に整って出力される．英語のアブストラクトは `\begin{eabstract}` と `\end{eabstract}` の間に書けば，次ページのような体裁で出力される．

両方を書けば，日本語と英語の両方のアブストラクトが並んで出力される（この文書はサンプルなので両方書いてある）．ページ順序は，コマンドを書いた順序の通り．どちらか一方のみを出力したい場合は，必要な方をコマンド自体を含め削除する．

このあたりの詳細もあとで書く．基本的には，`main.tex` を上から順にいじっていけばできるはず．

(2018/11 中村追記) ファイル分割を廃止し `main.tex` に統一している．

**キーワード：** キーワード 1, キーワード 2, キーワード 3

# 目次

第1章 序論	1
1.1 背景	1
1.2 本文書の構成	3
第2章 ドップラーレーダの原理	4
第3章 関連研究	6
3.1 ECG を基にした人物識別	6
3.2 呼吸信号を基にした人物識別	7
3.3 歩行特徴を基にした人物識別	9
第4章 従来法	10
4.1 心拍信号のスペクトログラムを用いた深層学習による人物 識別 [11]	10
4.1.1 手法	10
4.1.2 実験結果	11
4.2 心拍信号を基にした，双極子深層学習モデルによるオープ ンセット環境下における人物識別 [12]	11
4.2.1 手法	11
4.2.2 実験結果	12
4.3 心拍信号を基にした，転移学習とアンサンブル学習を用い たオープンセット環境下における人物識別 [13]	13
第5章 提案法	14

5.1	従来法の問題点と提案法 . . . . .	14
5.2	提案法のアルゴリズム . . . . .	15
<b>第 6 章</b>	<b>実験評価</b>	<b>21</b>
6.1	ノイズの少ないデータセットについて . . . . .	21
6.1.1	実験諸元 . . . . .	21
6.1.2	クローズセット環境下における実験結果 . . . . .	24
6.1.3	オープンセット環境下における実験結果 . . . . .	25
6.1.4	従来法との比較 . . . . .	26
6.2	ノイズの多いデータセットについて . . . . .	26
6.2.1	実験諸元 . . . . .	27
6.2.2	クローズセット環境下における実験結果 . . . . .	28
6.2.3	オープンセット環境下における実験諸元 . . . . .	29
<b>第 7 章</b>	<b>結論</b>	<b>32</b>
7.1	参考文献について . . . . .	32
	<b>謝辞</b>	<b>32</b>
	<b>参考文献</b>	<b>33</b>
<b>付 録 A</b>	<b>付録の例</b>	<b>39</b>
A.1	付録 1 . . . . .	39
A.1.1	あの . . . . .	39
A.2	なにか . . . . .	39
A.2.1	foo . . . . .	39

## 図 目 次

2.1	被験者に対しドップラーレーダで照射した様子 . . . . .	5
5.1	ノイズの少ない心拍信号データセットから取得した胸壁変位波形の例 . . . . .	16
5.2	ウェーブレット再構成適用前と適用後の波形の比較 . . . . .	17
5.3	InceptionTime の構造概要 . . . . .	19
5.4	提案法のアルゴリズム . . . . .	20
6.1	6 ポート CW レーダで心拍信号を計測する様子 [23] . . . . .	24
6.2	30 人の被験者の分類, ノイズの少ないデータセットでクローズセット環境の場合 . . . . .	25
6.3	30 人の被験者の分類, ノイズの少ないデータセットでオープンセット環境の場合. 既知の人物は 15 名, 未知の人物は 15 名, しきい値 0.7 . . . . .	26
6.4	12 人の被験者の分類, ノイズの多いデータセットでクローズセット環境の場合 . . . . .	29
6.5	12 人の被験者の分類, ノイズの多いデータセットでオープンセット環境の場合. 既知の人物は 6 名, 未知の人物は 6 名, しきい値 0.7 . . . . .	30

## 表 目 次

3.1	使用された 5 つの特徴量 . . . . .	8
4.1	各手法における 4 人の被験者のクローズセット環境下における精度の比較 . . . . .	11
4.2	クローズ/オープンセットにおける精度 . . . . .	12
6.1	エルランゲン大学で測定された心拍データセットの諸元 . . . . .	22
6.2	ハイパーパラメータ . . . . .	23
6.3	慶應大学病院で計測されたレーダ心拍信号の諸元 . . . . .	27
6.4	ハイパーパラメータ . . . . .	28

# 第1章 序論

## 1.1 背景

人物識別は多様なアプリケーションで利用されている。従来の識別は、指紋認証や顔認証といった対象となる人物の意図的な接触や協力が必要であり、煩わしさがある。また、パスワードを記憶しておく必要があったり、トークンを保持しておく必要がある [1]。特にカメラベースの識別は数多く考案されているものの、いずれもプライバシー保護の観点で問題があると言える。そこで近年、外的環境要因に強く、コストが低い、プライバシーの保護という観点から非接触で行うレーダベースの人物識別が注目を集めている。外的環境要因とは具体的に言えば、使用環境の照度、雪や霧といった悪天候、障害物などである。代替手段となりえるビジョンベースの LiDAR(Light Detection And Ranging) は環境要因に影響を受けやすく、被験者自身に装着するウェアラブルセンサーは対象人物の協力が必要となる [6]。また、Wi-Fi はチャンネルが混雑しており、干渉や環境ノイズの影響を強く受けてしまう。レーダを用いた識別は、見守りシステムや侵入者検知、継続的な認証など様々な場面における応用が期待されている [2]。継続的な認証とはレーダは、心拍や呼吸によって引き起こされる胸壁変位を検出可能である [2]。そのためレーダベースの識別では、心拍や呼吸といった生体信号や、歩行特徴といった信号を基に識別が行われるが、これ

はそれらの信号に人物に固有の特徴が含まれるためである．よって，なりすましがされにくいというメリットもある [12]．一方で体動によるノイズに弱く，それらをどのように除去するかは課題の1つとなっている．

元々ノイズの少ない心拍信号を用いるため，ECGを用いた

レーダの種類には CW(Continuous Wave) レーダ（ドップラーレーダ）や FMCW(Frequency Modulated Continuous Wave) レーダが近年，ドップラーレーダは様々な研究において，人間の生体信号を非接触に検出するハードウェアとして注目を集めている．・ECG(Electrocardiogram)を用いるのは，高い識別精度が得られるが，測定機器を持ち運ぶ必要があり，それを対象人物に装着する必要があるため，あまり実用的ではない．(Xing)・非接触の継続的な認証システムは，ログインセッションを通してシステムのセキュリティを維持する上で重要な役割を果たすことができる(呼吸SVM)

心拍や呼吸といった生体信号を用いた人物識別研究の多くは，テスト時に未知の人物が含まれないクローズセット環境下における評価をしており，テスト時に未知の人物が含まれるオープンセット環境下での評価を行っていない．そこで本研究では，オープンセット環境下におけるレーダ心拍信号を用いた人物識別を行う．ここではオープンセット環境を，既知の人物のクラス数を  $N$  として，未知の人物であるというクラスを1つ加えた  $N + 1$  個のクラスでの識別と定義する．

またここで，オープンネス指数を定義する． $C_{train}$  と  $C_{test}$  をそれぞれトレーニングセットとテストセットにおける被験者のクラス数である．オープンネス指数は，テスト時にモデルがどの程度の未知のクラスに遭遇するのかを定量化するために使用され，一般的にはこの指数が高いほど，分類



問題は困難になる [12]

$$openness = 1 - \sqrt{\frac{C_{train}}{C_{test}}} \quad (1.1)$$

## 1.2 本文書の構成

本論文は次のように構成される．第1章では，人物識別における背景と意義を述べた．第2章では，ドップラーレーダの基本原理について触れておく．第3章では，歩行特徴や呼吸といったレーダ心拍信号以外の生体信号を用いた人物識別の関連研究について述べる．第4章では，レーダ心拍信号を用いた本研究のベースラインとなる従来法について述べる．第5章では，Center Loss とウェーブレット再構成を用いたセグメント単位の人物識別アルゴリズムを提案する．第6章では，提案法の実験結果・評価を行い，第7章で本研究の結論を述べる．

## 第2章 ドップラーレーダの原理

本章では、胸壁の変位を取得するためのドップラーレーダの基本原理について述べる。レーダの基本原理はいくつかの研究で説明されている。レーダを人間の胸部へ波を送り、反射した波を取得する様子を図 2.1 に示す。レーダで照射した対象が変位すると、ドップラー効果により反射波の周波数が変化し、ドップラーシフトが発生する。送信波  $T(t)$  と受信波  $R(t)$  は式 2.1, 2.2 のように表せる。

$$T(t) = A_T \cos(2\pi ft + \phi(t)) \quad (2.1)$$

$$R(t) = A_R \cos(2\pi ft - \frac{4\pi d_0}{\lambda} - \frac{4\pi x(t)}{\lambda} + \phi(t - \frac{2d_0}{c})) \quad (2.2)$$

ただし、 $A_T, A_R$  はそれぞれ送信波と受信波の振幅、 $f$  は搬送波の周波数、 $\lambda$  は搬送波の波長、 $d_0$  はレーダと身体表面との距離、 $\phi(t)$  は位相ノイズ、 $x(t)$  は心拍により生じる胸壁変位である。

$R(t)$  がダウンコンバートされると、2つのベースバンド信号が得られ、同相信号  $I(t)$  と直交信号  $Q(t)$  は、式 2.3, 2.4 のように表せる。

$$I(t) = A_I \cos(\frac{4\pi x(t)}{\lambda} + \frac{4\pi d_0}{\lambda} + \theta + \frac{\pi}{4} + \Delta\phi(t)) \quad (2.3)$$

$$Q(t) = A_Q \cos(\frac{4\pi x(t)}{\lambda} + \frac{4\pi d_0}{\lambda} + \theta - \frac{\pi}{4} + \Delta\phi(t)) \quad (2.4)$$

$A_I, A_Q$  はそれぞれ  $I/Q$  信号の振幅、 $\theta$  は初期位相シフトである。




図 2.1: 被験者に対しドップラーレーダで照射した様子

## 第3章 関連研究

本章では，接触型の心拍信号，非接触型のレーダや Wi-Fi を用いて取得した歩行特徴や呼吸といった信号を基に人物識別を行った研究について述べる．(それぞれ 2-3 個出す)

### 3.1 ECG を基にした人物識別

ECG を用いて人物識別を行った最新の研究として，Lee らは ECG 信号を用いた 1 次元 LSTM(Long Short Term Memory) と 2 次元 CNN(Convolutional Neural Network) のアンサンブルアプローチを提案した．LPF(Low Pass Filter) で前処理された ECG 信号は，R ピークごとに周期でセグメントされ，片方は波形のまま LSTM へ，もう片方は，STFT(Short Time Fourier Transform), CWT(Continuous Wavelet Transform), FSST(Fourier Synchrosqueezed Transform), WSST(Wavelet Synchrosqueezed Transform) を用いて，時間-周波数領域へと変換された画像が CNN に入力される．CNN には事前学習された GoogleNet, VGG-19, ResNet-101 が用いられた．

## 3.2 呼吸信号を基にした人物識別

Islam らは、ドップラーレーダで取得した呼吸による、SVM(Support Vector Machine) による認証システムとして人物識別を行った [3]。彼らは SVM を動径基底関数カーネル分類と統合することで、非線形な問題の決定境界を学習可能とした。入力を被験者の呼吸パターンの FFT(Fast Fourier Transform) としており、既存の吸気と呼気のパターンに基づいて人物識別をする動的セグメンテーションの手法 [4][5] の精度を凌駕した。さらに、Islam らは上記の研究と同様に SVM を用いるが、異なる特徴量を採用した研究を発表しており、その研究では 5 種の特徴量が用いられている。特徴量を表 3.1

表 3.1: 使用された 5 つの特徴量

特徴量	算出方法
呼吸数/心拍数	測定された呼吸データに対し FFT を行い呼吸数を，呼吸信号に対し 0.8-2Hz の範囲で BPF(Band Pass Filter) を適用し，FFT を行うことで心拍数を抽出
呼吸ピークの平均距離/標準偏差	ピーク探索処理により呼吸データの最大/最小ピークとその時間指標を求め，ピークの平均距離と標準偏差を取得
呼吸深度	最小ピークから最大ピークまでの総変位量より算出
スペクトルエントロピー (信号の呼吸エネルギー)	呼吸データの信号振幅の 2 乗を取り，サンプル数を正規化することで算出
動的セグメンテーション	1 分間の呼吸サイクルを 30% 70% の振幅でセグメント化し，吸気部分と呼気部分の平均面積比 (= 次の呼吸の開始速度) を算出

### 3.3 歩行特徴を基にした人物識別

Yang らは、歩行特徴データに対して STFT(Short Time Fourier Transform) を行って得たスペクトログラムを用いて人物識別を行った [6]。この研究は、コートを着ている、カバンを所持している、ゆっくり歩くなどの通常の歩行とは異なる歩行についても考慮している点がそれ以前の研究とは異なる。モデルの学習段階で教師なしドメイン適応を行うことで、ソースドメインである通常歩行をターゲットドメインに近づけるアプローチを取っている。

Zhao らは、FMCW レーダを用いて適用可能な範囲内の人間の点群を生成し、その点群を追跡し、それらのデータフレームをリカレントニューラルネットワークへ入力することで人物識別を行っている [7]。点群は DBScan(Density-based spatial clustering of applications with noise)[8] でクラスタリングされ、カルマンフィルタ [9] を用いることで人物追跡の予測・修正を行い、Hungarian アルゴリズム [10] を用いることでトラックと人物の関連付けを行っている。

## 第4章 従来法

本章では，本研究と同様に心拍信号を用いて人物識別を行った研究について述べる．

### 4.1 心拍信号のスペクトログラムを用いた深層学習による人物識別 [11]

#### 4.1.1 手法

24 GHz? ドップラーレーダを用いて取得した心拍信号に対し，STFT(Short Time Fourier Transform) を実行して得たスペクトログラムが入力である．そして，時間軸と周波数軸で表現された特徴量を AlexNet を基にした DCNN(Deep Convolutional Neural Network) で抽出し，4 人の人物識別をクローズセット環境下で行った．[11] では，人物識別における深層学習の有用性を示している．比較手法として，SVM(Support Vector Machine), Naive Bayes, そしてそれらを組み合わせた手法の SVM-Bayes が挙げられており，用いられた手動の特徴量は以下の三種である．一つ目は，心拍信号の周期，二つ目は心拍信号のエネルギー，三つ目はドップラー信号の帯域幅である．



### 4.1.2 実験結果

先ほども触れたとおり，DCNN を用いた手法は伝統的な機械学習手法の精度を上回った．表 4.1 に各手法ごとの 4 人の被験者のクローズセット環境下における精度の比較を示す．

表 4.1: 各手法における 4 人の被験者のクローズセット環境下における精度の比較

手法	精度
DCNN	98.5%
SVM-Bayes	91.25%
SVM	88.75%
Naive Bayes	80.75%

## 4.2 心拍信号を基にした，双極子深層学習モデルによるオープンセット環境下における人物識別 [12]

### 4.2.1 手法

6 ポート CW(Continuous Wave) レーダを用いて取得した心拍信号が入力であり，使用されたデータセットは本研究でも評価した公開データセットである．手動の特徴量ではなく，1 次元の CNN(Convolutional Neural Network) を用いて特徴量を抽出して分類に使用する．それらの特徴量は

ユークリッド距離をベースとした損失関数を通してネットワークに学習される。各クラスにそれぞれ双極子が設定されており、損失関数はそれらの双極子とマッピングされた特徴量との距離が主な要素となっている。これらの損失関数はクラス内のクラスタリング、クラス間の分離をどちらも強化する。それによって、特徴量空間上でクラスがより分離可能な分布となる。また、双極子自体の分布も学習により調整され、抽出された特徴量とは敵対的学習の形をとる。識別の際にも双極子は使用され、ある心拍セグメントの潜在表現がクラス A の正極から閾値以上の距離があるか、負極から閾値以下の距離に存在する場合に、その心拍セグメントはクラス A と識別される。以上のように提案されたアーキテクチャは、オープンセット環境下で、学習に使用していない未知のデータに対しても対応できるように考案されたものである。

#### 4.2.2 実験結果

実験では、クローズセット環境下とオープンセット環境下の2つの状態で評価が行われた。表 4.2 に結果を示す。

表 4.2: クローズ/オープンセットにおける精度

環境	人数	精度
クローズセット	30	99.17%
オープンセット	15/15	93.57%

#### 4.3 心拍信号を基にした，転移学習とアンサンブル学習を用いたオープンセット環境下における人物識別 [13]

## 第5章 提案法

### 5.1 従来法の問題点と提案法

→ 特徴量が STFT の際に画像変換で失われてる DDLM を用いた手法. Distance-based な損失関数を使用. Decision making も特殊 (正? 極から閾値よりも離れているか, 負? 極に閾値よりも近いかで当該 ID かどうか判断) 未知の被験者を既知の被験者と判断してしまっている (混同行列). 複雑なアーキテクチャにもかかわらず, 訓練されたモデルがうまく出力をばらけさせられていない → 損失関数と分類器を工夫できているが, Open set の評価ではまだ精度が劣化してしまっており課題がある. CNN を 2 つ用いて OpenMax と Softmax でアンサンブル. ECG dataset による転移学習も活用している. → 2 つのモデルを訓練する必要がある. 損失関数が単純. 損失関数が単純 (DDLM は複雑) で, 特徴量のマッピングがばらけていないことが問題と考えられる全てに共通すること - Open-set での精度がまだまだ低い → モデルが出力する特徴量のマッピングがばらけていないことが原因と考える. unknown と known の距離が近い. → 損失関数に Softmax loss + Center loss を用いることでクラス内分散を最小化, クラス間分散を最大化する

## 5.2 提案法のアルゴリズム

提案法のアルゴリズムを図 5.4 に示す．本提案では，6 ポートのドップラーレーダで取得した I/Q データを用いた．I/Q データには心拍信号や呼吸信号に起因する胸壁の変位以外に，体動や I/Q チャネル間の振幅と位相の不均衡に起因するノイズが含まれている．

まず I/Q チャネル間の不均衡補償を行うため，楕円フィッティングを用いた．I/Q データが推定された理想的な楕円に近似されることで，より正確な変位信号を得ることができる [14][15]．そして，補償された I/Q データにアークタンジェント復調を施すことで，アンラップされた位相値を得ることができる．

そして位相値の変化を  $\Delta\sigma$ ，周波数を  $f$ ，光速を  $c$  とすれば，胸壁の相対距離の変化  $\Delta x$  は，次式のように計算できる．

$$\Delta x = \frac{\Delta\sigma}{2\pi} \cdot \frac{\lambda}{2} \quad (5.1)$$

そうして得られた胸壁変位波形の例を図 5.1 に示す．横軸はサンプリングされたポイントの数，縦軸は正規化された後の振幅をそれぞれ示している．




図 5.1: ノイズの少ない心拍信号データセットから取得した胸壁変位波形の例

本稿では、ノイズの少ないデータセットとノイズの多いデータセットの2つを使用するが、後者の場合には次に説明をするウェーブレット再構成を行う。ドップラーレーダで得た心拍信号や ECG(Electrocardiogram) からノイズ除去をするための手法の中で、いくつかの研究でウェーブレット再構成が使用されている [16, 17, 18]. 後者のデータセット中の胸壁変位信号には、レーダのキャリブレーションを含む高周波ノイズが含まれている。信号に対しウェーブレット変換を行うと、ウェーブレット係数を得ることができる。そしてそれらの係数に適切な閾値処理を施したあとに逆

ウェーブレット変換を行うことで、ノイズが除去された信号を得ることが可能である。今回はレベルを8、マザーウェーブレットを Daubechies8 とした。閾値処理では、最も高周波な成分を0として取り除いた。図5.2に被験者番号1の胸壁変位波形に対し、ウェーブレット再構成を適用する前後の波形の例を示す。横軸はサンプリングされたポイントの数、縦軸は正規化された後の振幅をそれぞれ示している。ウェーブレット再構成を適用した後の波形は、高周波のノイズが取り除かれていることが確認できる。




図 5.2: ウェーブレット再構成適用前と適用後の波形の比較

所望の信号を得られたら、次にセグメンテーションを行う。詳細な諸元については第6章で述べるが、セグメントのウィンドウ長は5秒、隣り合

うセグメントとのオーバーラップは1.5秒とした。

そしてセグメントは1次元のCNN(Convolutional Neural Network)によって学習が行われる。今回は時系列データの学習に適したInceptionTime[19]というモデルを採用した。図5.3にモデルの概要を示す。InceptionTimeの特徴として、画像認識で高い精度を残したInception モジュール [20] が6つ積み重ねられ、時系列データ用に特化させたことが挙げられる。Inception モジュールは、様々な大きさの畳み込み層と max プーリングの出力を結合させてまた、ResNet[21] に代表される残差接続を採用している点も大きな特徴の1つである。このような構造を持つため、InceptionTime は時系列データの特徴を最大限に抽出可能である。

損失関数には Softmax Loss と Center Loss の和  $L_{Total}$  を採用しており、以下のように定式化される [22]。

$$L_{\text{Softmax}} = \frac{1}{N} \sum_{i=1}^N 1 - \log \frac{e^{\|\mathbf{w}_{yi}\| * \|\mathbf{x}_i\| * \cos \theta_{yi} + \mathbf{b}_{yi}}}{\sum_{j=1}^C e^{\|\mathbf{w}_j\| * \|\mathbf{x}_i\| * \cos \theta_j + \mathbf{b}_j}} \quad (1)$$

$$L_{\text{Center}} = \frac{1}{2} \sum_{i=1}^N \|\mathbf{x}_i^j - \mathbf{c}^j\|_2, (j = 1, 2, \dots, C) \quad (2)$$

$$L_{\text{Total}} = L_{\text{Softmax}} + \alpha L_{\text{Center}} \quad (5.2)$$

1次元CNNの最終層にはSoftmax層があるが、Softmax層は既知の $N$ クラスにしかセグメントを分類することはできない。そこでオープンセット環境下では、Softmax-Thresholdという手法を採用し、これは、Softmaxの出力がある閾値以下であった場合にはその出力を未知のクラスに分類する方法である。






図 5.3: InceptionTime の構造概要




図 5.4: 提案法のアルゴリズム

## 第6章 実験評価

本章では実験結果を示し、その評価を述べる．評価指標として精度 (Accuracy) を用いる．精度は以下のように定義される．

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (6.1)$$

ただし、 $TP$  は True Positive,  $TN$  は True Negative,  $FP$  は False Positive,  $FN$  は False Negative である．

CrossEntropy vs Center Loss, Threshold の変化, Openness の変化に関するグラフ, Wavelet Reconstruction の有無

### 6.1 ノイズの少ないデータセットについて

本節では、ノイズの少ないデータセットを用いて、図 5.4 から、Center Loss によって効果的に被験者が分類されることを示す．

#### 6.1.1 実験諸元

エルランゲン大学病院にて 24GHz 6 ポート CW(Continuous Wave) レーダで収集された健康な 30 人の被験者で構成される公開データセットを使用した [23]．データセットの内容は表 6.1 のようになる．サンプリングレ

トは学習の段階で 2000 Hz から 250 Hz にリサンプリングして使用した。また、実際にレーダで被験者の心拍信号を測定する様子を図 6.1 に示す。レーダから被験者の身体表面までの距離は約 40cm に設定されている。実験を行った際のハイパーパラメータを表 6.2 に示す。モデルのオプティマイザには Adam(Adaptive moment) を使用した。Center Loss で使用するオプティマイザには SGD(Stochastic Gradient Descent) を使用した。

表 6.1: エルランゲン大学で測定された心拍データセットの諸元

被験者数	30
男性/女性	14/16
年齢	$30.7 \pm 9.9$
身長 (cm)	$175.7 \pm 10.5$
体重 (kg)	$72.2 \pm 14.0$
BMI	$23.2 \pm 3.3$
サンプリングレート (Hz)	2000
シナリオ	休息
平均計測時間 (秒)	2882

表 6.2: ハイパーパラメータ

被験者クラス数	30
既知/未知 (オープンセット)	15/15
エポック数	300
バッチサイズ	64
学習率	0.0001
ウィンドウ (秒)	5.0
オーバーラップ (秒)	1.5
$\alpha$ (Center Loss)	0.1
学習率 (Center Loss)	0.05




図 6.1: 6 ポート CW レーダで心拍信号を計測する様子 [23]

### 6.1.2 クローズセット環境下における実験結果

クローズセット環境で Center Loss を採用した提案手法は 99.94% の精度を達成した．図 6.2 に 10 分割交差検証を行った内の混同行列の例を示す．




図 6.2: 30 人の被験者の分類, ノイズの少ないデータセットでクローズセット環境の場合

### 6.1.3 オープンセット環境下における実験結果

既知の人物を 15 名, 未知の人物を 15 名として実験を行った. オープンセット環境で Center Loss を採用した提案手法は, Softmax-Threshold のしきい値が 0.7 の時, 99.02%の精度を達成した. 図 6.3 に 10 分割交差検証を行った内の混同行列の例を示す. ラベル 0-14 が既知の人物のクラスを表し, ラベル 15 が未知の人物のク既知の人物を 15 名, 未知の人物を 15 名として実験を行った. ラスを表す.




図 6.3: 30 人の被験者の分類, ノイズの少ないデータセットでオープンセット環境の場合. 既知の人物は 15 名, 未知の人物は 15 名, しきい値 0.7

#### 6.1.4 従来法との比較

## 6.2 ノイズの多いデータセットについて

本節では, ノイズの多いデータセットについて, 図 5.4 より, Center Loss に加えて前処理にウェーブレット再構成によるノイズ除去を行うことで, 提案手法が拡張されることを示す.



### 6.2.1 実験諸元

慶應大学病院で収集された12人の被験者で構成される非公開データセットを使用した。データセットの内容は表6.3の通りである。サンプリングレートは学習の段階で1000 Hzから250 Hzにリサンプリングして使用した。シナリオは休息であるものの、生データからは、体動等が原因と思われるノイズが確認されている。実験を行った際のハイパーパラメータを表6.4に示す。モデルとCenter Lossのオプティマイザはノイズの少ないデータセットの場合と同様で、それぞれAdamとSGDである。

表 6.3: 慶應大学病院で計測されたレーダ心拍信号の諸元

被験者数	12
被験者との水平距離 (cm)	$35.7 \pm 19.5$
被験者との垂直距離 (cm)	$146.1 \pm 7.1$
サンプリングレート	1000 Hz
シナリオ	休息

表 6.4: ハイパーパラメータ

被験者クラス数	12
既知/未知 (オープンセット)	6/6
エポック数	300
バッチサイズ	64
学習率	0.0001
ウィンドウ (秒)	5.0
オーバーラップ (秒)	1.5
$\alpha$ (Center Loss)	0.1
学習率 (Center Loss)	0.05

### 6.2.2 クローズセット環境下における実験結果

クローズセット環境で Center Loss とウェーブレット再構成を採用した提案手法は 78.02% の精度を達成した. 図 6.4 に 10 分割交差検証を行った内の混同行列の例を示す.




図 6.4: 12 人の被験者の分類, ノイズの多いデータセットでクローズセット環境の場合

### 6.2.3 オープンセット環境下における実験諸元

オープンセット環境で Center Loss とウェーブレット再構成を採用した提案手法は, Softmax-Threshold のしきい値が 0.7 の時, 42.28%の精度を達成した. 図 6.5 に 10 分割交差検証を行った内の混同行列の例を示す. ラベル 0-5 が既知の人物のクラスを表し, ラベル 6 が未知の人物のクラスを表す.




図 6.5: 12 人の被験者の分類, ノイズの多いデータセットでオープンセット環境の場合. 既知の人物は 6 名, 未知の人物は 6 名, しきい値 0.7

また、表??から、よりノイズが多く含まれる慶應病院のデータセットについて、ウェーブレット再構成を行った方がウェーブレット再構成を行わない場合、一般的な BPF の処理のみを行う場合よりも精度が大きく改善していることが分かる。

表??から、Center Loss が一般的に分類タスクに用いられる Cross Entropy Loss と比較して、精度が向上していることが分かる。

Openness を変化させていくと、図??より、未知のクラスと判断するためのしきい値を変化させていった場合に、0.7?で精度が最大となりその後

劣化していく事がわかる。これは、最大化するまでは未知のクラスを既知のクラスと間違い、その後は既知のクラスを未知のクラスと間違えているためである。既知のクラスの学習がうまくいっているほど、しきい値が高くなるにつれて

## 第7章 結論

### 7.1 参考文献について

このテンプレート中ではthebibliographyを使用しているが、BibTexのほうが使いやすいと思う場合は変更すること。引用フォーマットに関しては、IEEEのフォーマットIEEETranに筆者は合わせた。

# 謝辞

本研究を進めるにあたり，始終適切な御指導と御助言を賜りました慶應義塾大学理工学部情報工学科の大槻知明教授に深く感謝いたします。

また，本研究に関して多くの御指導をしてくださった大槻研究室の皆様に心から感謝いたします。

令和 5 年 2 月 3 日

慶應義塾大学理工学部情報工学科大槻研究室

権藤 陸

## 参考文献

- [1] L. O’Gorman, ”Comparing passwords, tokens, and biometrics for user authentication,” in Proceedings of the IEEE, vol. 91, no. 12, pp. 2021-2040, 2003.
- [2] J. Liu, H. Liu, Y. Chen, Y. Wang and C. Wang Wireless Sensing for Human Activity: A Survey IEEE Communications Surveys & Tutorials, vol. 22, no. 3, pp. 1629-1645, 2020,
- [3] S. M. M. Islam, A. Rahman, N. Prasad, O. Boric-Lubecke and V. M. Lubecke, ”Identity Authentication System using a Support Vector Machine (SVM) on Radar Respiration Measurements,” 2019 93rd ARFTG Microwave Measurement Conference (ARFTG), Boston, MA, USA, 2019, pp. 1-5
- [4] Feng Lin, Chen Song, Yan Zhuang, Wenyao Xu, Changzhi Li, and Kui Ren Cardiac Scan: A Non-contact and Continuous Heart-based User Authentication System. *In Proceedings of the 23rd Annual International Conference on Mobile Computing and Networking (MobiCom ’17)*. Association for Computing Machinery ,pp. 315–328, 2017



- [5] A. Rahman, V. M. Lubecke, O. Boric-Lubecke, J. H. Prins and T. Sakamoto Doppler Radar Techniques for Accurate Respiration Characterization and Subject Identification *IEEE Journal on Emerging and Selected Topics in Circuits and Systems*, vol. 8, no. 2, pp. 350-359, 2018
- [6] Y. Yang, X. Yang, T. Sakamoto, F. Fioranelli, B. Li and Y. Lang Unsupervised Domain Adaptation for Disguised-Gait-Based Person Identification on Micro-Doppler Signatures *IEEE Transactions on Circuits and Systems for Video Technology*, vol. 32, no. 9, pp. 6448-6460, 2022
- [7] Peijun Zhao, Chris Xiaoxuan Lu, Jianan Wang, Changhao Chen, Wei Wang, Niki Trigoni, Andrew Markham Human tracking and identification through a millimeter wave radar *Ad Hoc Networks*, Vol. 116, 2021
- [8] M. Ester, H.-P. Kriegel, J. Sander, X. Xu Density-based spatial clustering of applications with noise *Int. Conf. Knowledge Discovery and Data Mining*, Vol. 240, 1996
- [9] R.E. Kalman A new approach to linear filtering and prediction problems, 1960
- [10] H.W. Kuhn The Hungarian method for the assignment problem *Naval research logistics quarterly*, Vol. 2, No.1-2, pp.83-97, 1995.
- [11] AAA

- [12] Yang Bajiu,
- [13] Zelin Xing,
- [14] Aditya Singh, Xiaomeng Gao, Ehsan Yavari, Mari Zakrzewski, Xi Hang Cao, Victor M. Lubecke, Olga Boric-Lubecke Data-Based Quadrature Imbalance Compensation for a CW Doppler Radar System *IEEE Transactions on Microwave Theory and Techniques*, Vol.61, No.4, pp.1718-1724, 2013.
- [15] Mari Zakrzewski, Aditya Singh, Ehsan Yavari, Xiaomeng Gao, Olga Boric-Lubecke, Jukka Vanhala, Karri Palovuori Quadrature Imbalance Compensation With Ellipse-Fitting Methods for Microwave Radar Physiological Sensing *IEEE Transactions on Microwave Theory and Techniques*, Vol.62, No.6, pp.1400-1408, 2014.
- [16] Xiaoling Li, Bin Liu, Yang Liu, Jiawei Li, Jiarui Lai, Ziming Zheng A Novel Signal Separation and De-Noising Technique for Doppler Radar Vital Signal Detection *Sensors* Vol. 19, No. 21, 2019
- [17] Nguyen Dinh Chinh, Luu Manh Ha, Guanghao Sun, Le Quoc Anh, Pham Viet Huong, Tran Anh Vu, Tran Trong Hieu, Tran Duc Tan, Nguyen Vu Trung, Koichiro Ishibashi, Nguyen Linh Trung Short time cardio-vascular pulses estimation for dengue fever screening via continuous-wave Doppler radar using empirical mode decomposition and continuous wavelet transform *Biomedical Signal Processing and Control*, Vol. 65, 2021

- [18] C. Haritha, M. Ganesan and E. P. Sumesh A survey on modern trends in ECG noise removal techniques *2016 International Conference on Circuit, Power and Computing Technologies (ICCPCT)*, pp. 1-7, 2016
- [19] Hassan Ismail Fawaz, Benjamin Lucas, Germain Forestier, Charlotte Pelletier, Daniel F. Schmidt, Jonathan Weber, Geoffrey I. Webb, Lhassane Idoumaghar, Pierre-Alain Muller, Francois Petitjean InceptionTime: Finding AlexNet for time series classification *Data Mining and Knowledge Discovery*, Vol.34, No.6, pp.1936-1962, 2020.
- [20] Szegedy, Christian, et al. "Inception-v4, inception-resnet and the impact of residual connections on learning." Thirty-first AAAI conference on artificial intelligence. 2017.
- [21] He, Kaiming, et al. "Deep residual learning for image recognition." Proceedings of the IEEE conference on computer vision and pattern recognition. 2016.
- [22] Wen, Y., Zhang, K., Li, Z., Qiao, Y.. A Discriminative Feature Learning Approach for Deep Face Recognition. In: Leibe, B., Matas, J., Sebe, N., Welling, M. (eds) *Computer Vision – ECCV 2016*. ECCV 2016. Lecture Notes in Computer Science(), vol 9911. Springer, Cham, 2016
- [23] Sven Schellenberger, Kilin Shi, Tobias Steigleder, Anke Malessa, Fabian Michler, Laura Hameyer, Nina Neumann, Fabian Lurz,

Robert Weigel, Christoph Ostgathe, Alexander Koelpin A dataset of clinically recorded radar vital signs with synchronised reference sensor signals *Sci Data*, Vol. 7, p. 291, 2020

## 付 録 A 付録の例

付録を無理矢理出力させるため、てきとうなことを書く

### A.1 付録 1

コマンドは本文と一緒に.

#### A.1.1 あの

あのイーハトーヴォのすきとおった風，夏でも底に冷たさをもつ青いそら，うつくしい森で飾られたモリーオ市，郊外のぎらぎらひかる草の波.

### A.2 なにか

あのイーハトーヴォのすきとおった風，夏でも底に冷たさをもつ青いそら，うつくしい森で飾られたモリーオ市，郊外のぎらぎらひかる草の波.

#### A.2.1 foo

あのイーハトーヴォのすきとおった風，夏でも底に冷たさをもつ青いそら，うつくしい森で飾られたモリーオ市，郊外のぎらぎらひかる草の波.