

卒業論文

オープンセット環境下における  
レーダ心拍信号を用いた深層学習  
による人物識別

慶應義塾大学理工学部情報工学科

大槻研究室

学籍番号 61908013

権 藤 陸

指導教員：大槻知明 教授

提出 令和5年2月3日

## 卒業論文概要 2022 年度（令和 4 年度）

# オープンセット環境下におけるレーダ心拍信号を用いた深層学習による人物識別

レーダによって取得された心拍や呼吸信号を用いた認証は、非接触で実行可能であること、プライバシーが保護されること、対象人物の無意識下で継続的な認証ができる可能性から注目を集めている。多くの研究がテスト時に未知の人物を含まないクローズセット環境で行われているが、本研究では、実世界の条件に即したオープンセット環境下で人物識別の精度を高める手法を提案する。

提案法では、心拍により発生する胸壁変位信号を入力とし、1次元のCNN(Convolutional Neural Network)で人物に固有の特徴を抽出する。損失関数にSoftmax LossとCenter Lossを採用することで、モデルは特徴量空間におけるマッピングが、容易にクラスごとに分離可能になるよう学習されていく。提案法は従来法の精度をクローズセット、オープンセットの両方で凌駕した。またウェーブレット再構成を導入し、提案法がよりノイズの多いデータに対しても対応できる可能性を示した。

**キーワード：** オープンセット, Center Loss, ウェーブレット再構成

# 目次

第1章 序論	1
1.1 背景	1
1.2 目的	2
1.3 本文書の構成	3
第2章 ドップラーレーダの原理	4
第3章 関連研究	6
3.1 ECG を基にした人物識別	6
3.2 呼吸信号を基にした人物識別	6
3.3 歩行特徴を基にした人物識別	9
第4章 従来法	10
4.1 心拍信号のスペクトログラムを用いた深層学習による人物 識別 [16]	10
4.1.1 手法	10
4.1.2 実験結果	11
4.2 心拍信号を基にした，双極子深層学習モデルによるオーブ ンセット環境下における人物識別 [17]	11
4.2.1 手法	11
4.2.2 実験結果	12
4.3 心拍信号を基にした，転移学習と2つのモデルを用いたオー ブンセット環境下における人物識別 [19]	13

4.3.1	手法 . . . . .	13
4.3.2	実験結果 . . . . .	13
<b>第 5 章</b>	<b>提案法</b>	<b>15</b>
5.1	従来法の問題点と提案法 . . . . .	15
5.2	提案法のアルゴリズム . . . . .	16
<b>第 6 章</b>	<b>実験評価</b>	<b>22</b>
6.1	ノイズの少ないデータセットについて . . . . .	22
6.1.1	実験諸元 . . . . .	22
6.1.2	クローズセット環境下における実験結果 . . . . .	25
6.1.3	オープンセット環境下における実験結果 . . . . .	26
6.1.4	一般的な損失関数との比較 . . . . .	27
6.1.5	従来法との比較 . . . . .	28
6.2	ノイズの多いデータセットについて . . . . .	29
6.2.1	実験諸元 . . . . .	29
6.2.2	クローズセット環境下における実験結果 . . . . .	30
6.2.3	オープンセット環境下における実験結果 . . . . .	31
6.2.4	一般的な損失関数との比較 . . . . .	32
6.2.5	ウェーブレット再構成の有効性の評価 . . . . .	33
6.3	Threshold, Openness による精度の変化 . . . . .	33
<b>第 7 章</b>	<b>結論</b>	<b>37</b>
	<b>謝辞</b>	<b>37</b>



## 目 次

2.1	被験者に対しドップラーレーダで照射した様子 . . . . .	5
5.1	提案法のアルゴリズム . . . . .	17
5.2	ノイズの少ない心拍信号データセットから取得した胸壁変 位波形の例 . . . . .	18
5.3	ウェーブレット再構成適用前と適用後の 1 秒間の波形の比較	19
5.4	ウェーブレット再構成適用前と適用後の 900 秒間の波形の 比較 . . . . .	19
5.5	InceptionTime の構造概要 . . . . .	21
6.1	6 ポート CW レーダで心拍信号を計測する様子 [31] . . . . .	25
6.2	30 人の被験者の分類, ノイズの少ないデータセットでクロ ズセット環境の場合 . . . . .	26
6.3	30 人の被験者の分類, ノイズの少ないデータセットでオー プンセット環境の場合. 既知の人物は 15 名, 未知の人物は 15 名, しきい値 0.7 . . . . .	27
6.4	12 人の被験者の分類, ノイズの多いデータセットでクロ ズセット環境の場合 . . . . .	31
6.5	12 人の被験者の分類, ノイズの多いデータセットでオー プンセット環境の場合. 既知の人物は 6 名, 未知の人物は 6 名, しきい値 0.7 . . . . .	32
6.6	Openness による精度の変化 . . . . .	35
6.7	Threshold による精度の変化 . . . . .	36

## 表 目 次

3.1	使用された 5 つの特徴量 . . . . .	8
4.1	各手法における 4 人の被験者のクローズセット環境下における精度の比較 . . . . .	11
4.2	クローズ/オープンセットにおける精度 . . . . .	12
4.3	クローズ/オープンセットにおける精度 . . . . .	14
6.1	エルランゲン大学で測定された心拍データセットの諸元 . . . . .	23
6.2	ハイパーパラメータ . . . . .	24
6.3	損失関数を変更した場合の比較 . . . . .	28
6.4	2 つの従来法と提案法との比較 . . . . .	28
6.5	慶應大学病院で計測されたレーダ心拍信号の諸元 . . . . .	29
6.6	ハイパーパラメータ . . . . .	30
6.7	損失関数を変更した場合の比較 . . . . .	33
6.8	前処理を変更した場合の比較 . . . . .	33

# 第1章 序論

## 1.1 背景

人物識別は多様なアプリケーションで利用されている。従来の識別は、指紋認証や顔認証といった対象となる人物の意図的な接触や協力が必要であることに加え、煩わしさがある。また、パスワードを記憶しておく必要があったり、トークンを保持しておく必要がある [1]。特にカメラベースの識別は既に実生活でも数多く実装されているものの、いずれもプライバシー保護の観点で問題があると言える。そこで近年、外的環境要因に強く、コストが低い、プライバシーの保護という観点から非接触で行うレーダベースの人物識別が注目を集めている。外的環境要因とは具体的に言えば、使用環境の照度、雪や霧といった悪天候、障害物などである [2, 3, 4]。代替手段となりえるビジョンベースの LiDAR (Light Detection And Ranging) は環境要因に影響を受けやすく、被験者自身に装着するウェアラブルセンサーは対象人物の協力が必要となる。また、Wi-Fi はチャンネルが混雑しており、干渉や環境ノイズの影響を強く受けてしまう [5]。レーダを用いた識別は、見守りシステムや侵入者検知、継続的な認証など様々な場面における応用が期待されている [2]。継続的な認証とはユーザが入室やデバイスの認証といったセッション開始時に一度だけ認証される従来の認証とは異なり、定期的に何度も認証を行うことを指し、より強固なセキュリティ



をもたらす [6].

レーダは、心拍や呼吸によって引き起こされる胸壁変位を検出可能である [2]. そのためレーダベースの識別では、心拍や呼吸といった生体信号や、歩行特徴といった信号を基に識別が行われるが、これはそれらの信号に人物に固有の特徴が含まれるためである. よって、なりすましがされにくいというメリットもある [17]. 一方で体動によるノイズに弱く、それらをどのように除去するかは課題の 1 つとなっている.

元々ノイズの少ない心拍信号を用いるために、ECG を用いた研究は多く存在する [7, 8, 9]. しかし、測定機器を持ち運び、対象人物に装着させる必要があるため、あまり実用的ではない [19]. それゆえ本研究では、ドップラーレーダを用いた非接触な人物識別を行う.

レーダで取得した心拍や呼吸といった生体信号を用いた従来の人物識別研究の多くは、テスト時に未知の人物が含まれないクローズセット環境下における評価をしており、テスト時に未知の人物が含まれるオープンセット環境下での評価を行っていない. そこで本研究では、オープンセット環境下におけるレーダ心拍信号を用いた人物識別を行う. ここではオープンセット環境を、既知の人物のクラス数を  $N$  として、未知の人物であるというクラスを 1 つ加えた  $N + 1$  個のクラスでの識別と定義する.

## 1.2 目的

本論文では、Center Loss とウェーブレット再構成を用いて、オープンセット環境下における提案アルゴリズムの人物識別の精度改善、ノイズの多いデータセットに対しても高い精度を達成することを目指す.

### 1.3 本文書の構成

本論文は次のように構成される．第1章では，人物識別における背景と意義を述べた．第2章では，ドップラーレーダの基本原理について触れておく．第3章では，歩行特徴や呼吸といったレーダ心拍信号以外の生体信号を用いた人物識別の関連研究について述べる．第4章では，レーダ心拍信号を用いた本研究のベースラインとなる従来法について述べる．第5章では，Center Loss とウェーブレット再構成を用いたセグメント単位の人物識別アルゴリズムを提案する．第6章では，提案法の実験結果・評価を行い，第7章で本研究の結論を述べる．

## 第2章 ドップラーレーダの原理

本章では、胸壁の変位を取得するためのドップラーレーダの基本原理について述べる。レーダの基本原理はいくつかの研究で説明されている。レーダを人間の胸部へ波を送り、反射した波を取得する様子を図 2.1 に示す。レーダで照射した対象が変位すると、ドップラー効果により反射波の周波数が変化し、ドップラーシフトが発生する。送信波  $T(t)$  と受信波  $R(t)$  は式 2.1, 2.2 のように表せる。

$$T(t) = A_T \cos(2\pi ft + \phi(t)) \quad (2.1)$$

$$R(t) = A_R \cos(2\pi ft - \frac{4\pi d_0}{\lambda} - \frac{4\pi x(t)}{\lambda} + \phi(t - \frac{2d_0}{c})) \quad (2.2)$$

ただし、 $A_T, A_R$  はそれぞれ送信波と受信波の振幅、 $f$  は搬送波の周波数、 $\lambda$  は搬送波の波長、 $d_0$  はレーダと身体表面との距離、 $\phi(t)$  は位相ノイズ、 $x(t)$  は心拍により生じる胸壁変位である。

$R(t)$  がダウンコンバートされると、2つのベースバンド信号が得られ、同相信号  $I(t)$  と直交信号  $Q(t)$  は、式 2.3, 2.4 のように表せる。

$$I(t) = A_I \cos(\frac{4\pi x(t)}{\lambda} + \frac{4\pi d_0}{\lambda} + \theta + \frac{\pi}{4} + \Delta\phi(t)) \quad (2.3)$$

$$Q(t) = A_Q \cos(\frac{4\pi x(t)}{\lambda} + \frac{4\pi d_0}{\lambda} + \theta - \frac{\pi}{4} + \Delta\phi(t)) \quad (2.4)$$

$A_I, A_Q$  はそれぞれ  $I/Q$  信号の振幅、 $\theta$  は初期位相シフトである。

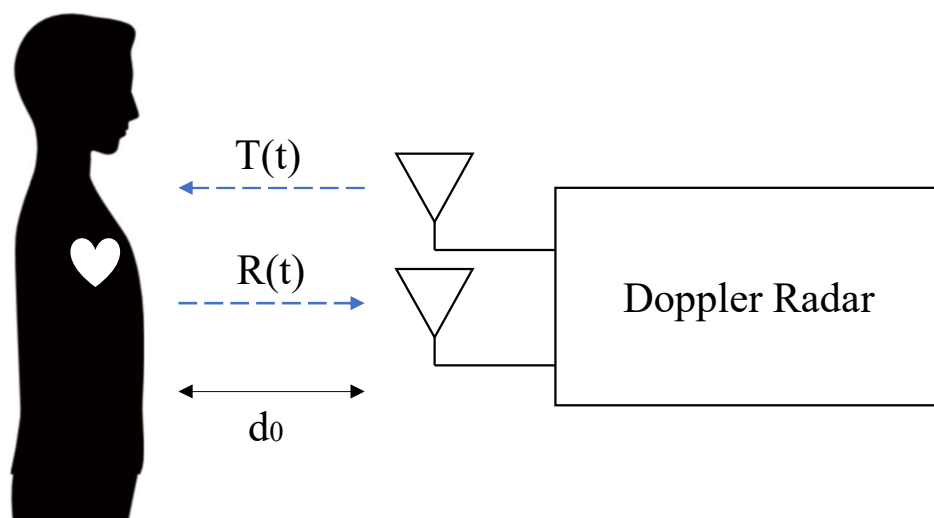


図 2.1: 被験者に対しドップラーレーダで照射した様子

## 第3章 関連研究

本章では，接触型の心拍信号，非接触型のレーダを用いて取得した歩行特徴や呼吸といった信号を基に人物識別を行った研究について述べる．

### 3.1 ECG を基にした人物識別

ECG を用いて人物識別を行った最新の研究として，Lee らは ECG 信号を用いた 1 次元 LSTM(Long Short Term Memory) と 2 次元 CNN(Convolutional Neural Network) のアンサンブルアプローチを提案した [9]．LPF(Low Pass Filter) で前処理された ECG 信号は，R ピークごとに周期でセグメントされ，片方は波形のまま LSTM へ，もう片方は，STFT(Short Time Fourier Transform), CWT(Continuous Wavelet Transform), FSST(Fourier Synchrosqueezed Transform), WSST(Wavelet Synchrosqueezed Transform) を用いて，時間-周波数領域へと変換された画像が CNN に入力される．CNN には事前学習された GoogleNet, VGG-19, ResNet-101 が用いられた．

### 3.2 呼吸信号を基にした人物識別

Islam らは，ドップラーレーダで取得した呼吸による，SVM(Support Vector Machine) による認証システムとして人物識別を行った [3]．彼らは

SVMを動径基底関数カーネル分類と統合することで、非線形な問題の決定境界を学習可能とした．入力を被験者の呼吸パターンのFFT(Fast Fourier Transform)としており、既存の吸気と呼気のパターンに基づいて人物識別をする動的セグメンテーションの手法 [10][11] の精度を凌駕した．さらに、Islam らは上記の研究と同様に SVM を用いるが、異なる特徴量を採用した研究を発表しており、その研究では5種の特徴量が用いられている．特徴量を表 3.1 に示す．

表 3.1: 使用された 5 つの特徴量

特徴量	算出方法
呼吸数/心拍数	測定された呼吸データに対し FFT を行い呼吸数を, 呼吸信号に対し 0.8-2Hz の範囲で BPF(Band Pass Filter) を適用し, FFT を行うことで心拍数を抽出
呼吸ピークの平均距離/標準偏差	ピーク探索処理により呼吸データの最大/最小ピークとその時間指標を求め, ピークの平均距離と標準偏差を取得
呼吸深度	最小ピークから最大ピークまでの総変位量より算出
スペクトルエントロピー (信号の呼吸エネルギー)	呼吸データの信号振幅の 2 乗を取り, サンプル数を正規化することで算出
動的セグメンテーション	1 分間の呼吸サイクルを 30% 70% の振幅でセグメント化し, 吸気部分と呼気部分の平均面積比 (= 次の呼吸の開始速度) を算出

### 3.3 歩行特徴を基にした人物識別

Yang らは、歩行特徴データに対して STFT(Short Time Fourier Transform) を行って得たスペクトログラムを用いて人物識別を行った [5]。この研究は、コートを着ている、カバンを所持している、ゆっくり歩くなどの通常の歩行とは異なる歩行についても考慮している点がそれ以前の研究とは異なる。モデルの学習段階で教師なしドメイン適応を行うことで、ソースドメインである通常歩行をターゲットドメインに近づけるアプローチを取っている。

Zhao らは、FMCW レーダを用いて適用可能な範囲内の人間の点群を生成し、その点群を追跡し、それらのデータフレームをリカレントニューラルネットワークへ入力することで人物識別を行っている [12]。点群は DBScan(Density-based spatial clustering of applications with noise)[13] でクラスタリングされ、カルマンフィルタ [14] を用いることで人物追跡の予測・修正を行い、Hungarian アルゴリズム [15] を用いることでトラックと人物の関連付けを行っている。



## 第4章 従来法

本章では，本研究と同様に心拍信号を用いて人物識別を行った研究について述べる．

### 4.1 心拍信号のスペクトログラムを用いた深層学習による人物識別 [16]

#### 4.1.1 手法

24 GHz ドップラーレーダを用いて取得した心拍信号に対し，STFT(Short Time Fourier Transform) を実行して得たスペクトログラムが入力である．そして，時間軸と周波数軸で表現された特徴量を AlexNet を基にした DCNN(Deep Convolutional Neural Network) で抽出し，4 人の人物識別をクローズセット環境下で行った．[16] では，人物識別における深層学習の有用性を示している．比較手法として，SVM(Support Vector Machine), Naive Bayes, そしてそれらを組み合わせた手法の SVM-Bayes が挙げられており，用いられた手動の特徴量は以下の三種である．一つ目は，心拍信号の周期，二つ目は心拍信号のエネルギー，三つ目はドップラー信号の帯域幅である．

### 4.1.2 実験結果

先ほども触れたとおり，DCNN を用いた手法は伝統的な機械学習手法の精度を上回った．表 4.1 に各手法ごとの 4 人の被験者のクローズセット環境下における精度の比較を示す．

表 4.1: 各手法における 4 人の被験者のクローズセット環境下における精度の比較

手法	精度
DCNN	98.5%
SVM-Bayes	91.25%
SVM	88.75%
Naive Bayes	80.75%

## 4.2 心拍信号を基にした，双極子深層学習モデルによるオープンセット環境下における人物識別 [17]

### 4.2.1 手法

6 ポート CW(Continuous Wave) レーダを用いて取得した心拍信号が入力であり，使用されたデータセットは本研究でも評価した公開データセットである．手動の特徴量ではなく，1 次元の CNN(Convolutional Neural Network) を用いて特徴量を抽出して分類に使用する．それらの特徴量は

ユークリッド距離をベースとした損失関数を通してネットワークに学習される。各クラスにそれぞれ双極子が設定されており、損失関数はそれらの双極子とマッピングされた特徴量との距離が主な要素となっている。これらの損失関数は、各クラスに距離ベースの類似性を与え、従来の関数よりも特徴量空間上でクラスがより分離可能な分布とするはたらきがある。また、双極子自体の分布も学習により調整され、抽出された特徴量とは敵対的学習の形をとる。識別の際にも双極子は使用され、ある心拍セグメントの潜在表現がクラス A の正極からしきい値以上の距離があるか、負極からしきい値以下の距離に存在する場合に、その心拍セグメントはクラス A と識別される。以上のように提案されたアーキテクチャは、オープンセット環境下で、学習に使用していない未知のデータに対しても対応できるように考案されたものである。

#### 4.2.2 実験結果

実験では、クローズセット環境下とオープンセット環境下の2つの状態で評価が行われた。表 4.2 に結果を示す。

表 4.2: クローズ/オープンセットにおける精度

環境	人数	精度
クローズセット	30	99.17%
オープンセット	15/15	93.57%

## 4.3 心拍信号を基にした，転移学習と2つのモデルを用いたオープンセット環境下における人物識別 [19]

### 4.3.1 手法

本研究と同様の公開データセットに含まれる，心拍信号セグメントを用いて人物識別を行っている研究である．2種のモデルと分類器を用いて最終的な識別を行っているのが特徴であり，一方のモデルでは分類器はSoftMaxだが，もう一方のモデルではオープンセットの分類に適したOpenMax[18]という分類器が用いられている．このOpenMaxはテストデータ中に含まれる未知のクラスを識別することに貢献している．2つのモデルはECGのデータセットで事前学習されたものを，さらにレーダ心拍信号を用いてキャリブレーションして学習を行っている．クラスを識別する際には，2つの分類器から出力された確率のスコアを組み合わせることでより高い精度の識別に成功している．

### 4.3.2 実験結果

実験では，クローズセット環境下とオープンセット環境下の2つの状態で評価が行われた．表4.3に結果を示す．

表 4.3: クローズ/オープンセットにおける精度

環境	人数	精度
クローズセット	30	98.76%
オープンセット	15/15	94.35%

## 第5章 提案法

### 5.1 従来法の問題点と提案法

従来法 [16] では，STFT を用いた時間-周波数画像 (ヒートマップ) を入力とした CNN による分類が提案されているが，STFT の弱点として，特徴量が画像に変換される際に失われてしまう点にあると考えられる．従来法 [17], [19] では，損失関数やクラスの識別方法に複雑なアーキテクチャを採用し，高い識別精度を達成しているものの，オープンセット環境下ではクローズセット環境に比べて精度が劣化してしまっているという問題がある．これは，各クラスの特徴量空間におけるマッピングが互いに近すぎるが故に，未知の被験者を既知の被験者と誤って（逆も然り）判断してしまっているためであると考えられる．

そこで本研究では，損失関数に Softmax loss と Center loss を用いることでクラス内分散を最小化しつつ，クラス間分散を最大化させ，オープンセット環境下でも精度が劣化しにくいモデルを提案する．さらに，ノイズの多いデータセットについても検討を行い，ウェーブレット再構成を導入することでノイズの多いデータに対しても効果的に識別ができることを示す．

## 5.2 提案法のアルゴリズム

提案法のアルゴリズムを図 5.1 に示す. ノイズの少ないデータセットについては分岐 A が, ノイズの多いデータセットについては分岐 B が適用される.

本提案では, 6 ポートのドップラーレーダで取得した I/Q データを用いた. I/Q データには心拍信号や呼吸信号に起因する胸壁の変位以外に, 体動や I/Q チャネル間の振幅と位相の不均衡に起因するノイズが含まれている.

まず I/Q チャネル間の不均衡補償を行うため, 楕円フィッティングを用いた. I/Q データが推定された理想的な楕円に近似されることで, より正確な変位信号を得ることができる [20][21]. そして, 補償された I/Q データにアークタンジェント復調を施すことで, アンラップされた位相値を得ることができる.

そして位相値の変化を  $\Delta\sigma$ , 周波数を  $f$ , 光速を  $c$  とすれば, 胸壁の相対距離の変化  $\Delta x$  は, 次式のように計算できる.

$$\Delta x = \frac{\Delta\sigma}{2\pi} \cdot \frac{\lambda}{2} \quad (5.1)$$

そうして得られた胸壁変位波形の例を図 5.2 に示す. 横軸はサンプリングされたポイントの数, 縦軸は正規化された後の振幅をそれぞれ示している.

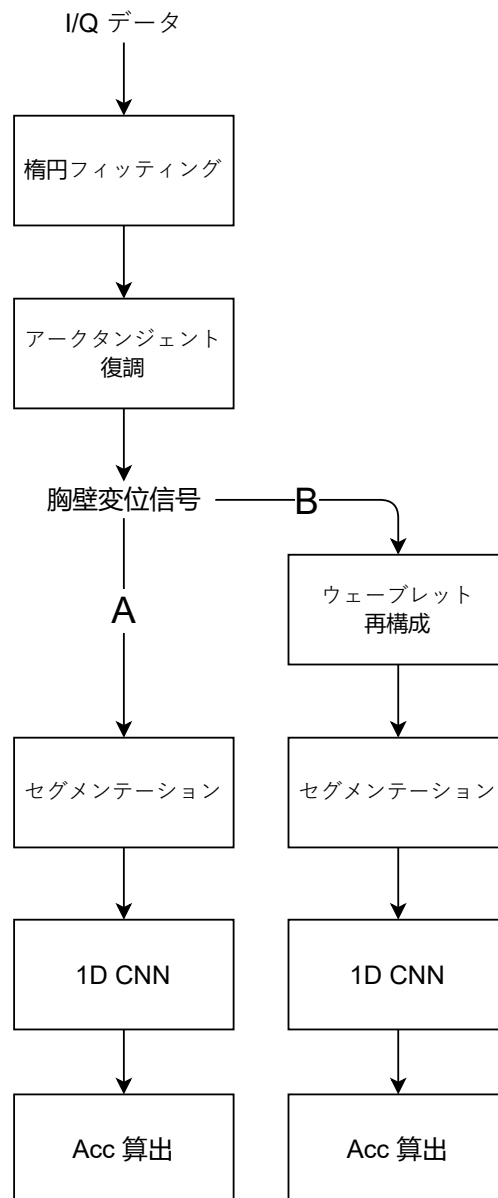


図 5.1: 提案法のアルゴリズム






図 5.2: ノイズの少ない心拍信号データセットから取得した胸壁変位波形の例

本稿では、ノイズの少ないデータセットとノイズの多いデータセットの2つを使用するが、後者の場合には次に説明をするウェーブレット再構成を行う。ドップラーレーダで得た心拍信号や ECG(Electrocardiogram) からノイズ除去をするための手法の中で、いくつかの研究でウェーブレット再構成が使用されている [22, 23, 24]。後者のデータセット中の胸壁変位信号には、レーダのキャリブレーションを含む高周波ノイズが含まれている。信号に対しウェーブレット変換を行うと、ウェーブレット係数を得ることができる。そしてそれらの係数に適切なしきい値処理を施したあとに

逆ウェーブレット変換を行うことで、ノイズが除去された信号を得ることが可能である。パラメータを変えながら実験を行い、レベルを6、マザーウェーブレットはDaubechies8とした。Daubechiesは、ECGやレーダ信号のノイズ除去に適したマザーウェーブレットである[25, 26]。しきい値処理では、最も低周波な成分を0として取り除いた。図5.2に被験者番号1の胸壁変位波形に対し、ウェーブレット再構成を適用する前後の波形の例を示す。横軸は時間、縦軸は正規化された後の振幅をそれぞれ示している。ウェーブレット再構成を適用した後の波形は、左図からは体動等の影響と考えられる低周波ノイズが低減され、右図からはキャリブレーションの影響による波形のジャンプが除去されていることが確認できる。





図 5.3: ウェーブレット再構成適用前と適用後の1秒間の波形の比較      図 5.4: ウェーブレット再構成適用前と適用後の900秒間の波形の比較

所望の信号を得られたら、次にセグメンテーションを行う。詳細な諸元については第6章で述べるが、セグメントのウィンドウ長は5秒、隣り合うセグメントとのオーバーラップは1.5秒とした。

そしてセグメントは1次元のCNN(Convolutional Neural Network)によ

って学習が行われる．今回は時系列データの学習に適した InceptionTime[27] というモデルを採用した．図 5.5 にモデルの概要を示す．InceptionTime の特徴として，画像認識で高い精度を残した Inception モジュール [28] が 6 つ 積み重ねられ，時系列データ用に特化させたことが挙げられる．Inception モジュールは，様々な大きさの畳み込み層と max プーリングの出力を結合させてまた，ResNet[29] に代表される残差接続を採用している点も大きな特徴の 1 つである．このような構造を持つため，InceptionTime は時系列データの特徴を最大限に抽出可能である．

損失関数には Softmax Loss と Center Loss の和  $L_{Total}$  を採用しており，以下のように定式化される [30]．

$$L_{\text{Softmax}} = \frac{1}{N} \sum_{i=1}^N 1 - \log \frac{e^{\|\mathbf{w}_{yi}\| * \|\mathbf{x}_i\| * \cos \theta_{yi} + \mathbf{b}_{yi}}}{\sum_{j=1}^C e^{\|\mathbf{w}_j\| * \|\mathbf{x}_i\| * \cos \theta_j + \mathbf{b}_j}} \quad (5.2)$$

$$L_{\text{Center}} = \frac{1}{2} \sum_{i=1}^N \|\mathbf{x}_i^j - \mathbf{c}^j\|_2, (j = 1, 2, \dots, C) \quad (5.3)$$

$$L_{\text{Total}} = L_{\text{Softmax}} + \alpha L_{\text{Center}} \quad (5.4)$$

式 5.2 において  $w_j, w_{yi}, b_j, b_{yi}$  はネットワークの最後の全結合層の重み行列とバイアス項、 $\theta_j$  は高次元空間における重みベクトルと特徴ベクトルの間の角度である．Softmax Loss はネットワークの出力が正解ラベルと近い分布になるようにし，クラス間分散を最大化させる．式 5.3 において、 $N$  は  $j$  番目のクラスのサンプル数、 $x_i^j$  は  $j$  番目のクラスに属する  $i$  番目のサンプル、 $c_j$  は  $j$  番目のクラスの中心であることを表している．Center Loss は各クラスの中心を計算し，その周辺に同じクラスの特徴量を拘束することでクラス内分散を最小化する．

1次元CNNの最終層にはSoftmax層があるが、Softmax層は既知の $N$ クラスにしかセグメントを分類することはできない。そこでオープンセット環境下では、Softmax-Thresholdという手法を採用し、これは、Softmax出力の最大値があるしきい値以下であった場合にはその出力を未知のクラスに分類する方法である。




図 5.5: InceptionTime の構造概要

## 第6章 実験評価

本章では実験結果を示し，その評価を述べる．評価指標として精度 (Accuracy) を用いる．精度は以下のように定義される．

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (6.1)$$

ただし， $TP$  は True Positive,  $TN$  は True Negative,  $FP$  は False Positive,  $FN$  は False Negative である．

### 6.1 ノイズの少ないデータセットについて

本節では，ノイズの少ないデータセットを用いて，図 5.1 から，Center Loss によって効果的に被験者が分類されることを示す．

#### 6.1.1 実験諸元

エルランゲン大学病院にて 24GHz 6 ポート CW(Continuous Wave) レーダで収集された健康な 30 人の被験者で構成される公開データセットを使用した [31]．データセットの内容は表 6.1 のようになる．サンプリングレートは学習の段階で 2000 Hz から 250 Hz にリサンプリングして使用した．また，実際にレーダで被験者の心拍信号を測定する様子を図 6.1 に示す．

レーダから被験者の身体表面までの距離は約 40cm に設定されている．実験を行った際のハイパーパラメータを表 6.2 に示す．モデルのオプティマイザには Adam(Adaptive moment) を使用した．Center Loss で使用するオプティマイザには SGD(Stochastic Gradient Descent) を使用した．

表 6.1: エルランゲン大学で測定された心拍データセットの諸元

被験者数	30
男性/女性	14/16
年齢	$30.7 \pm 9.9$
身長 (cm)	$175.7 \pm 10.5$
体重 (kg)	$72.2 \pm 14.0$
BMI	$23.2 \pm 3.3$
サンプリングレート (Hz)	2000
シナリオ	休息
平均計測時間 (秒)	2882

表 6.2: ハイパーパラメータ

被験者クラス数	30
既知/未知 (オープンセット)	15/15
エポック数	300
バッチサイズ	64
学習率	0.0001
ウィンドウ (秒)	5.0
オーバーラップ (秒)	1.5
$\alpha$ (Center Loss)	0.1
学習率 (Center Loss)	0.05




図 6.1: 6 ポート CW レーダで心拍信号を計測する様子 [31]

### 6.1.2 クローズセット環境下における実験結果

クローズセット環境で Center Loss を採用した提案手法は 99.94% の精度を達成した．図 6.2 に 10 分割交差検証を行った内の混同行列の例を示す．






図 6.2: 30 人の被験者の分類, ノイズの少ないデータセットでクローズセット環境の場合

### 6.1.3 オープンセット環境下における実験結果

既知の人物を 15 名, 未知の人物を 15 名として実験を行った. オープンセット環境で Center Loss を採用した提案手法は, Softmax-Threshold のしきい値が 0.7 の時, 99.02%の精度を達成した. 図 6.3 に 10 分割交差検証を行った内の混同行列の例を示す. ラベル 0-14 が既知の人物のクラスを表し, ラベル 15 が未知の人物のクラスを表す.




図 6.3: 30 人の被験者の分類, ノイズの少ないデータセットでオープンセット環境の場合. 既知の人物は 15 名, 未知の人物は 15 名, しきい値 0.7

#### 6.1.4 一般的な損失関数との比較

本研究では特徴量マッピングを分散させ, より未知の人物を精度高く分類するための Center Loss を採用したが, ここでは一般的に分類タスクで用いられる Cross Entropy Loss を用いた場合との比較を表 6.3 に示す. 表より, Center Loss を用いた場合の方が 10.4%精度が改善していることが分かる. つまり, 本提案手法において, Center Loss の精度への寄与が高いことが伺える.

表 6.3: 損失関数を変更した場合の比較

環境	手法	既知/未知の人数	精度
オープンセット	Cross Entropy Loss	15/15	88.60%
	Center Loss	15/15	99.02%

### 6.1.5 従来法との比較

従来法 [17, 19] は本節で用いているデータセットと同一のものを使用しているため, ここで表 6.4 に従来法と提案法の精度の比較を示す. 表からいずれの環境下においても, Center Loss を用いた提案法が2つの従来法の精度を凌駕していることが確認できる.

表 6.4: 2つの従来法と提案法との比較

環境	手法	既知/未知の人数	精度
クローズセット	Yan et al.[17]	(30/0)	99.17%
	Xing et al.[19]	(30/0)	98.76%
	<b>提案法 (Center Loss)</b>	(30/0)	<b>99.94%</b>
オープンセット	Yan et al.[17]	15/15	93.57%
	Xing et al.[19]	15/15	94.35%
	<b>提案法 (Center Loss)</b>	15/15	<b>99.02%</b>

## 6.2 ノイズの多いデータセットについて

本節では，ノイズの多いデータセットについて，図 5.1 の B のアルゴリズムを適用し，Center Loss に加えて前処理にウェーブレット再構成によるノイズ除去を行うことで，提案手法が拡張されることを示す．

### 6.2.1 実験諸元

慶應大学病院で収集された 12 人の被験者で構成される非公開データセットを使用した．データセットの内容は表 6.5 の通りである．サンプリングレートは学習の段階で 1000 Hz から 250 Hz にリサンプリングして使用した．シナリオは休息であるものの，生データからは，体動等が原因と思われるノイズが確認されている．実験を行った際のハイパーパラメータを表 6.6 に示す．モデルと Center Loss のオプティマイザはノイズの少ないデータセットの場合と同様で，それぞれ Adam と SGD である．

表 6.5: 慶應大学病院で計測されたレーダ心拍信号の諸元

被験者数	12
被験者との水平距離 (cm)	$35.7 \pm 19.5$
被験者との垂直距離 (cm)	$146.1 \pm 7.1$
サンプリングレート	1000 Hz
シナリオ	休息

表 6.6: ハイパーパラメータ

被験者クラス数	12
既知/未知 (オープンセット)	6/6
エポック数	300
バッチサイズ	64
学習率	0.0001
ウィンドウ (秒)	5.0
オーバーラップ (秒)	1.5
$\alpha$ (Center Loss)	0.1
学習率 (Center Loss)	0.05

### 6.2.2 クローズセット環境下における実験結果

クローズセット環境で Center Loss とウェーブレット再構成を採用した提案手法は 84.80% の精度を達成した. 図 6.4 に 10 分割交差検証を行った内の混同行列の例を示す.




図 6.4: 12 人の被験者の分類, ノイズの多いデータセットでクローズセット環境の場合

### 6.2.3 オープンセット環境下における実験結果

オープンセット環境で Center Loss とウェーブレット再構成を採用した提案手法は, Softmax-Threshold のしきい値が 0.7 の時, 42.28%の精度を達成した. 図 6.5 に 10 分割交差検証を行った内の混同行列の例を示す. ラベル 0-5 が既知の人物のクラスを表し, ラベル 6 が未知の人物のクラスを表す.




図 6.5: 12 人の被験者の分類, ノイズの多いデータセットでオープンセット環境の場合. 既知の人物は 6 名, 未知の人物は 6 名, しきい値 0.7

#### 6.2.4 一般的な損失関数との比較

ノイズの少ないデータセットでは Center Loss が精度改善に寄与していることが分かったが, ノイズの多いデータセットでも改善が見られるかどうかを調べた. 結果を表 6.7 に示す. 表から, 精度が 1.6% 改善しており, データセットが変わった場合にも Center Loss は精度改善に寄与することが確認できた. このとき, どちらの手法についても前処理には BPF を用いている.

表 6.7: 損失関数を変更した場合の比較

環境	手法	既知/未知の人数	精度
オープンセット	Cross Entropy Loss	6/6	45.69%
	Center Loss	6/6	47.27%

### 6.2.5 ウェーブレット再構成の有効性の評価

続いて、ウェーブレット再構成が精度改善にどれほど寄与しているかを述べる。表 6.8 に、ウェーブレット再構成の有無、一般的な前処理である BPF を用いた場合の比較を示す。表から、ウェーブレット再構成を前処理に導入した提案法が最も高い精度を達成していることが分かる。表の 1 行目の空欄は、図 5.2 で示したウェーブレット再構成を行わない場合の胸壁変位波形をそのまま CNN の入力に使用したことを示している。

表 6.8: 前処理を変更した場合の比較

環境	手法	既知/未知の人数	精度
クローズセット		(12/0)	18.21%
	BPF	(12/0)	47.27%
	提案法 (ウェーブレット再構成)	(12/0)	84.80%

## 6.3 Threshold, Openness による精度の変化

本節では 2 つのデータセットで Openness によって精度がどう変化していくか、また Softmax-Threshold のしきい値によって精度がどう変化して



いくつか述べる.

ここで, Openness 指数を定義する.  $C_{train}$  と  $C_{test}$  をそれぞれトレーニングセットとテストセットに含まれる被験者のクラス数である. Openness 指数は, テスト時にモデルがどの程度の未知のクラスに遭遇するのかを定量化するために使用され, 一般的にはこの指数が高いほど, 分類問題は困難になる [17].

$$openness = 1 - \sqrt{\frac{C_{train}}{C_{test}}} \quad (6.2)$$

図 6.6 と図 6.7 に精度のしきい値による変化と Openness による変化のグラフを示した.

Openness を変化させていくと, 図 6.6 より, エルランゲン大学のデータセットは精度がほとんど 100% に上ずっていて変化が見られないが, 慶應病院のデータセットでは Openness が上がっていくことで精度が劣化していき, 問題が難しくなっていることが読み取れる.

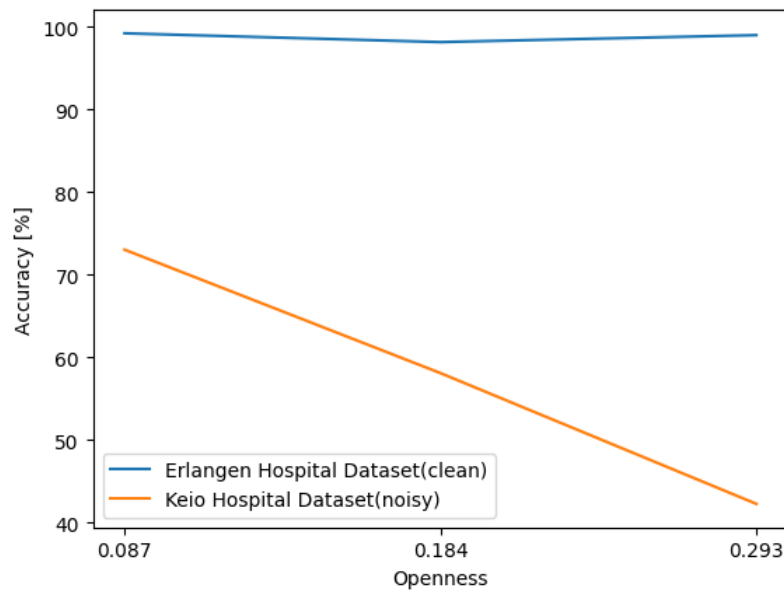


図 6.6: Openness による精度の変化

Threshold を変化させていくと、図 6.7 より、エルランゲン大学のグラフは、しきい値を変化させていった場合に、0.7(0.8) で精度が最大となりその後劣化している事がわかる。これは、既知のクラスの学習がうまくいっているほど、既知クラスが入力となった時の Softmax の出力値の分布が 1 付近の値に偏るためである。精度が最大化するまでは未知のクラスを既知のクラスと誤り、その後は既知のクラスを未知のクラスと誤っているのである。慶應病院のデータセットは Softmax の出力値の分布の偏りがエルランゲン大学のデータセットを使用した場合と比較してあまりないために、そのような傾向は見られず、精度が変化しないと考えられる。




図 6.7: Threshold による精度の変化

## 第7章 結論

本研究では，従来法でオープンセット環境下における精度の劣化を克服するため，Center Loss を採用した．そして提案手法は従来法の精度をオープンセットで 4.7%，クローズセットでも 0.8% 上回った．また，ウェーブレット再構成で提案手法をさらに拡張し，よりノイズが多いデータについても対応ができるようなアルゴリズムであると示された．

今後の課題として，Softmax-Threshold のしきい値を静的に決定することは実用上難しいと考えられるため，動的に識別の基準を決めて，未知のクラスを出力できるようにすることが挙げられる．また，ノイズが大きい慶應病院のデータセットについてはまだ精度改善の余地が残されているため，ウェーブレット係数のしきい値処理の工夫等のさらなる前処理の探求や新たな学習のアーキテクチャの考案が必要である．

# 謝辞

本研究を進めるにあたり，始終適切な御指導と御助言を賜りました慶應義塾大学理工学部情報工学科の大槻知明教授に深く感謝いたします。

また，本研究に関して多くの御指導をしてくださった大槻研究室の皆様に心から感謝いたします。

令和 5 年 2 月 3 日

慶應義塾大学理工学部情報工学科大槻研究室

権藤 陸

## 参考文献

- [1] L. O’Gorman Comparing passwords, tokens, and biometrics for user authentication *Proceedings of the IEEE*, Vol. 91, No. 12, pp. 2021-2040, 2003.
- [2] J. Liu, H. Liu, Y. Chen, Y. Wang and C. Wang Wireless Sensing for Human Activity: A Survey *IEEE Communications Surveys & Tutorials*, vol. 22, no. 3, pp. 1629-1645, 2020,
- [3] S. M. M. Islam, A. Rahman, N. Prasad, O. Boric-Lubecke and V. M. Lubecke Identity Authentication System using a Support Vector Machine (SVM) on Radar Respiration Measurements *2019 93rd ARFTG Microwave Measurement Conference (ARFTG)*, pp. 1-5, 2019
- [4] S. M. M. Islam, A. Sylvester, G. Orpilla and V. M. Lubecke Respiratory feature extraction for radar-based continuous identity authentication *2020 IEEE Radio and Wireless Symposium (RWS)*. pp. 119-122, 2020.
- [5] Y. Yang, X. Yang, T. Sakamoto, F. Fioranelli, B. Li and Y. Lang Unsupervised Domain Adaptation for Disguised-Gait-Based Person

- Identification on Micro-Doppler Signatures *IEEE Transactions on Circuits and Systems for Video Technology*, vol. 32, no. 9, pp. 6448-6460, 2022
- [6] Dahia, Gabriel, Leone Jesus, and Mauricio Pamplona Segundo Continuous authentication using biometrics: An advanced review *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*, Vol. 10, No. 4, 2020
- [7] Biel L, Pettersson O, Philipson L, Wide P ECG analysis: A new approach in human identification *IEEE Trans. Instrum. Meas.* Vol. 50, pp.808-812, 2001
- [8] M. Ingale, R. Cordeiro, S. Thentu, Y. Park and N. Karimian ECG biometric authentication: A comparative analysis *IEEE Access*, Vol. 8, pp.117853-117866
- [9] J.-A. Lee and K.-C. Kwak Personal Identification Using an Ensemble Approach of 1D-LSTM and 2D-CNN with Electrocardiogram Signals *Applied Sciences*, Vol. 12, No. 5, p. 2692, 2022
- [10] Feng Lin, Chen Song, Yan Zhuang, Wenyao Xu, Changzhi Li, and Kui Ren Cardiac Scan: A Non-contact and Continuous Heart-based User Authentication System. *In Proceedings of the 23rd Annual International Conference on Mobile Computing and Networking (MobiCom '17)*. Association for Computing Machinery ,pp. 315–328, 2017

- [11] A. Rahman, V. M. Lubecke, O. Boric-Lubecke, J. H. Prins and T. Sakamoto Doppler Radar Techniques for Accurate Respiration Characterization and Subject Identification *IEEE Journal on Emerging and Selected Topics in Circuits and Systems*, vol. 8, no. 2, pp. 350-359, 2018
- [12] Peijun Zhao, Chris Xiaoxuan Lu, Jianan Wang, Changhao Chen, Wei Wang, Niki Trigoni, Andrew Markham Human tracking and identification through a millimeter wave radar *Ad Hoc Networks*, Vol. 116, 2021
- [13] M. Ester, H.-P. Kriegel, J. Sander, X. Xu Density-based spatial clustering of applications with noise *Int. Conf. Knowledge Discovery and Data Mining*, Vol. 240, 1996
- [14] R.E. Kalman A new approach to linear filtering and prediction problems, 1960
- [15] H.W. Kuhn The Hungarian method for the assignment problem *Naval research logistics quarterly*, Vol. 2, No.1-2, pp.83-97, 1995.
- [16] P. Cao, W. Xia, and Y. Li Heart ID: Human Identification Based on Radar Micro-Doppler Signatures of the Heart Using Deep Learning *Remote Sensing*, Vol. 11, No. 10, p. 1220, 2019
- [17] Baiju Yan, Hao Zhang, Yicheng Yao, Changyu Liu, Pu Jian, Peng Wang, Lidong Du, Xianxiang Chen, Zhen Fang, Yirong Wu Heart



- signatures: Open-set person identification based on cardiac radar signals *Biomedical Signal Processing and Control*, Vol. 72, 2022
- [18] Giusti E, Ghio S, Oveis AH, Martorella M. Proportional Similarity-Based Openmax Classifier for Open Set Recognition in SAR Images *Remote Sensing*, Vol. 14, No. 18, 2022
- [19] Zelin Xing, Mondher Bouazizi, Tomoaki Ohtsuki Deep Learning-based Open-set Person Identification using Radar Extracted Cardiac Signals, 2022
- [20] Aditya Singh, Xiaomeng Gao, Ehsan Yavari, Mari Zakrzewski, Xi Hang Cao, Victor M. Lubecke, Olga Boric-Lubecke Data-Based Quadrature Imbalance Compensation for a CW Doppler Radar System *IEEE Transactions on Microwave Theory and Techniques*, Vol.61, No.4, pp.1718-1724, 2013.
- [21] Mari Zakrzewski, Aditya Singh, Ehsan Yavari, Xiaomeng Gao, Olga Boric-Lubecke, Jukka Vanhala, Karri Palovuori Quadrature Imbalance Compensation With Ellipse-Fitting Methods for Microwave Radar Physiological Sensing *IEEE Transactions on Microwave Theory and Techniques*, Vol.62, No.6, pp.1400-1408, 2014.
- [22] Xiaoling Li, Bin Liu, Yang Liu, Jiawei Li, Jiarui Lai, Ziming Zheng A Novel Signal Separation and De-Noising Technique for Doppler Radar Vital Signal Detection *Sensors* Vol. 19, No. 21, 2019

- [23] Nguyen Dinh Chinh, Luu Manh Ha, Guanghao Sun, Le Quoc Anh, Pham Viet Huong, Tran Anh Vu, Tran Trong Hieu, Tran Duc Tan, Nguyen Vu Trung, Koichiro Ishibashi, Nguyen Linh Trung Short time cardio-vascular pulses estimation for dengue fever screening via continuous-wave Doppler radar using empirical mode decomposition and continuous wavelet transform *Biomedical Signal Processing and Control*, Vol. 65, 2021
- [24] C. Haritha, M. Ganesan and E. P. Sumesh A survey on modern trends in ECG noise removal techniques *2016 International Conference on Circuit, Power and Computing Technologies (ICCPCT)*, pp. 1-7, 2016
- [25] Y. I. Jang, J. Y. Sim, J.-R. Yang, and N. K. Kwon The Optimal Selection of Mother Wavelet Function and Decomposition Level for Denoising of DCG Signal *Sensors*, Vol. 21, No. 5, p. 1851, 2021
- [26] P. B. Patil and M. S. Chavan A wavelet based method for denoising of biomedical signal *International Conference on Pattern Recognition, Informatics and Medical Engineering (PRIME-2012)*, pp. 278-283, 2012
- [27] Hassan Ismail Fawaz, Benjamin Lucas, Germain Forestier, Charlotte Pelletier, Daniel F. Schmidt, Jonathan Weber, Geoffrey I. Webb, Lhassane Idoumaghar, Pierre-Alain Muller, Francois Petitjean In-

- ceptionTime: Finding AlexNet for time series classification *Data Mining and Knowledge Discovery*, Vol.34, No.6, pp.1936-1962, 2020.
- [28] zegedy C., Ioffe S., Vanhoucke V., Alemi, A. Inception-v4, Inception-ResNet and the Impact of Residual Connections on Learning *Proceedings of the AAAI Conference on Artificial Intelligence*, Vol. 31, No. 1, 2017
- [29] Kaiming He, Xiangyu Zhang, Shaoqing Ren, Jian Sun Deep residual learning for image recognition *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2016
- [30] Wen, Y., Zhang, K., Li, Z., Qiao, Y.. A Discriminative Feature Learning Approach for Deep Face Recognition. In: Leibe, B., Matas, J., Sebe, N., Welling, M. (eds) *Computer Vision – ECCV 2016*. ECCV 2016. Lecture Notes in Computer Science(), vol 9911. *Springer, Cham*, 2016
- [31] Sven Schellenberger, Kilin Shi, Tobias Steigleder, Anke Malessa, Fabian Michler, Laura Hameyer, Nina Neumann, Fabian Lurz, Robert Weigel, Christoph Ostgathe, Alexander Koelpin A dataset of clinically recorded radar vital signs with synchronised reference sensor signals *Sci Data*, Vol. 7, p. 291, 2020