

PPG 信号を用いた動脈血圧波形予測のための ドメイン敵対的学習による深層生成モデル

Deep generative model with domain adversarial training for predicting
arterial blood pressure waveform from photoplethysmogram signal

権藤陸

Riku Gondo

慶應義塾大学 理工学部¹

Faculty of Science and Technology, Keio university

1 はじめに

長期的な血圧モニタリングは、個人の健康状態の変化を動的に反映することができ、潜在的な疾患の警告と予防に大きな意味を持つ [1] [2]。しかし、現在の血圧測定的主流は上腕を圧迫するカフをベースとした方法であり、不便であるため利用シーンが限られる。一方で近年、ウェアラブルセンサを用いた連続的な血圧モニタリングが注目を集めており、特に PPG (Photoplethysmogram) センサは、その安価さと手首や指先で信号を測定できる利便性から、血圧測定など幅広い応用が期待されている [3] [4]。PPG 信号から動脈血圧波形を生成できれば、血管に対し侵襲的に血圧を計測する方法の代替として、感染の危険性がなく、より安全であることから、このアプローチは潜在的な応用価値を持つ [5]。

一方で、PPG 信号と血圧の波形は被験者の健康状態によって大きく左右されてしまい、特に集中治療室患者で深刻である。このような個人差は、血圧予測を困難にさせる。

これらの事実を踏まえ、我々は、動脈血圧波形予測のための、データの個人差を考慮した深層生成モデルを開発した。

2 従来法

2.1 特徴量を手動で設定する機械学習による血圧予測

Xing らは、FFT に基づく PPG 信号の振幅と位相情報を用いて、多層パーセプトロンによって、1 拍ごとの血圧を予測している [6]。

この研究では、特徴量の抽出を波形の特徴点の位置に依存しており、高品質のデータが必要である。そのため、複雑な特徴抽出や選択・変換処理に加え、データの品質を確保するための精緻な前処理やスクリーニングが必要になる点が課題である。

2.2 特徴量を自動で学習する深層学習による血圧予測

Eom らは、VGGNet という畳み込みモデルと Bi-GRU 層を重ねたモデルを提案した。このモデルでは、時間方向に沿った特徴ベクトルの重要度を定量化するためにセルフアテンション機構が利用されている [7]。

このような深層学習ベースのアプローチは、各タスク (SBP¹, DBP², または MBP³) 予測に対して独立した予測モデルを学習する従来の機械学習ベースのアプローチとは異なり、1 つのモデルのみで事足りる。しかし、SBP, DBP, MBP の間で損失スケールが異なると、モデルの学習に支障をきたすという別の問題が生じる。

2.3 ABP 波形予測

前提として、我々の知る限り、血圧波形を直接予測した研究はほとんどない。Ibetezhaz [8] らは、医用画像分野の古典的なネットワークである UNet [9] をディープスーパービジョンの概念と組み合わせて、PPG 信号から ABP 波形の生成に適

用している。しかし、上記の研究のいずれも異なる被験者から得られたデータ間の個人差を考慮していない。

3 提案法

3.1 RDAE (Regularized Deep Autoencoder)

RDAE は教師ありディープオートエンコーダであり、損失関数に正則化項を加えることで、ドメイン敵対的学習を実現したモデルである。入出力データである生理信号の周期性とパターン反復性を考慮し、RNN (Recurrent Neural Network) と比較して計算量が小さい 1 次元畳み込み層を採用した。

本稿では、各個人の記録をドメインとみなす。そして、RDAE では、エンコーダと分類器が敵対的に学習を進めることを”ドメイン敵対的学習”と呼んでいる。具体的には、エンコーダは信号変換誤差を最小化し、分類器の識別能力を弱らせる方向に学習を進め、分類器は、各 PPG 信号の潜在表現の所属クラス (個人) を識別する方向に学習を進める。

本モデルが最適化すべき目的関数は以下ようになる。

$$l(\phi, \varphi, \pi) = E_{(x, y) \sim P_{data}} L_r(D_\varphi(E_\phi(x)), y) - \lambda \cdot L_d(D_\pi(E_\phi(x)), d_x) \quad (1)$$

第一項は信号変換損失を表し、 L_r は MAE (Mean Absolute Error) を表し、 P_{data} は x, y は未知の $X \times Y$ の事前分布である P_{data} から取り出されたサンプルである。第二項はドメイン分類器に対する分類損失を表し、 L_d は交差エントロピー誤差で計算される。 λ はハイパーパラメータで、二項の重みを決定する。

そして、各パラメータの更新式は以下のように表される。

$$\pi \leftarrow \pi - \alpha \lambda \cdot \nabla_\pi L_d, \quad (2)$$

$$\varphi \leftarrow \varphi - \alpha \cdot \nabla_\varphi L_r, \quad (3)$$

$$\phi \leftarrow \phi - \alpha \cdot \nabla_\phi (L_r - \lambda \cdot L_d) \quad (4)$$

- エンコーダのパラメータ ϕ 、デコーダのパラメータ φ 、ドメイン分類器のパラメータ π を全て初期化する。
- バッチサイズ分のサンプルを取り出し、潜在ベクトル z を計算する。
- ドメイン分類器の出力を計算する。
- 分類器の出力に対する勾配を計算し、分類器のパラメータ π を (2) 式に従い更新する。
- 2 をもう一度実行し、分類器とデコーダの出力を計算する。
- 分類器とデコーダの出力に対する勾配を計算し、エンコーダのパラメータ ϕ を (3) 式に従い更新する。
- デコーダの出力に対する勾配を計算し、デコーダのパラメータ φ を (4) 式に従い更新する。
- 1-7 を推定精度が収束するか、最大エポック数を超えるまで繰り返す。

¹SBP: Systolic Blood Pressure

²DBP: Diastolic Blood Pressure

³MBP: Mean Blood Pressure

3.2 キャリブレーション

キャリブレーションはソースドメインでの学習モデルをターゲットドメインに適合させる手法である。確立されたヘルスケア規格は、評価プロセス中のテストデバイスのキャリブレーションを許可していないが、実際のアプリケーションでは、個人の血圧関連データが継続的に測定・記録されるため、個人の履歴データを用いてモデルをキャリブレーションすることは容易であると考えられる。本研究では、各テストレコードについてその最初の8サンプルを用いて、学習済みのモデルをさらに学習（キャリブレーション）する。

4 実験

1227人の被験者からPPG信号を検出し、ABP波形を推定した。MIMICII データセット [10] に含まれる PPG 信号と ABP 信号を真値として以下に示すように精度指標を計算した。

- 平均絶対誤差 (MAE: Mean Absolute Error)

$$MAE = \frac{1}{N} \sum_{i=1}^N |p_i - \hat{p}_i| \quad (5)$$

- 平均誤差 (ME: Mean Error)

$$ME = \frac{1}{N} \sum_{i=1}^N |p_i - \hat{p}_i| \quad (6)$$

- 標準偏差 (STD: Standard Deviation)

$$STD = \sqrt{\frac{\sum_{i=1}^N (\hat{p}_i - \bar{p})^2}{N}} \quad (7)$$

ただし、

- N : 被験者数
- p_i : 血圧の真値
- \hat{p}_i : 血圧の推定値
- \bar{p} : 血圧推定値の平均値

図1は、推定したABP波形と真値の比較である。赤で示された推定波形が青の真値の波形を高精度に予測できていると確認できる。




図1: 推定 ABP 波形と真値の比較

表1は、通常のディープオートエンコーダ (DAE) とドメイン敵対的学習が含まれた RDAE、そしてキャリブレーションありの RDAE の比較である。結果は平均値で示され、括弧内は標準誤差である。表の下へ行くほど、3つの指標 (MAE, ME, STD) の標準誤差が小さくなるため、ドメイン敵対的学習によるロバスト性向上が確認できる。同様に、MAE が小さくなることで、キャリブレーションによるモデルの予測精度向上が確認できる。

表1 ドメイン敵対的学習とキャリブレーションの精度比較

Method	Task	Metrics (unit: mmHg)		
		MAE	ME	STD
DAE (pool)	SBP	9.568(0.801)	2.090(2.469)	12.278(0.871)
	DBP	4.865(0.234)	-0.581(0.807)	6.477(0.342)
	MBP	4.699(0.170)	0.309(1.150)	6.204(0.218)
DAE	SBP	8.082(0.538)	1.024(1.398)	10.559(0.682)
	DBP	4.179(0.485)	-0.322(0.858)	5.569(0.574)
	MBP	3.903(0.315)	0.126(0.795)	5.210(0.390)
RDAE	SBP	7.945(0.389)	1.447(0.877)	10.372(0.532)
	DBP	4.114(0.237)	-0.417(0.641)	5.504(0.396)
	MBP	3.834(0.242)	0.204(0.436)	5.130(0.349)
DAE (with calibration)	SBP	5.734(0.265)	1.686(0.431)	7.009(0.335)
	DBP	3.175(0.255)	-1.328(0.256)	3.787(0.272)
	MBP	2.979(0.147)	-0.323(0.257)	3.522(0.168)
RDAE (with calibration)	SBP	5.424(0.164)	1.648(0.319)	6.640(0.190)
	DBP	3.144(0.162)	-1.280(0.208)	3.740(0.172)
	MBP	2.885(0.147)	-0.304(0.181)	3.412(0.173)

表2は、提案法と従来法の MAE とパラメータ数を比較したものである。表から、提案法は従来法に予測精度が少し劣る部分もあるが、パラメータ数の小さいモデルとなっていることが確認できる。

表2 提案法と従来法の比較

Split criterion	Cal. Method	Dataset	#Record used	#Sample	Signals	Input	MAE (mmHg)			#Param.	
							SBP	DBP	MBP		
split at record level	No	RDAE (proposed)	MIMIC II	1227	39264	PPG, ABP	Raw signal	7.945	4.114	3.834	6.490M
		Rack [16]	MIMIC II	1912	3663	PPG, ECG, ABP	Raw signal	9.30	5.12	-	17.596M
		Kachuee [14]	MIMIC II	3663	3663	PPG, ECG, ABP	Features	11.17	5.35	5.92	-
		Thambiraj [34]	MIMIC II	3801	3801	PPG, ECG, ABP	Features	9.00	5.48	3.2	-
		Eom [19]	Private	15	Unknown	PPG, ECG, BCG	Raw signal	9.70	5.79	-	10.648M
		Slapnicar [8]	MIMIC III	510	700h	PPG, ECG, ABP	Raw signal	15.41	12.38	-	3.523M
	Yes	RDAE (proposed)	MIMIC II	1227	39264	PPG, ABP	Raw signal	5.424	3.144	2.885	6.490M
		Rack [16]	MIMIC II	1912	3663	PPG, ECG, ABP	Raw signal	5.32	3.38	-	17.596M
		Kachuee [14]	MIMIC II	3663	3663	PPG, ECG, ABP	Features	8.21	4.31	-	-
		Zhang [17]	Private	11	Unknown	PPG, ABP	Raw signal	6.79	4.48	-	0.045M
		Eom [19]	Private	15	Unknown	PPG, ECG, BCG	Raw signal	4.06	3.33	-	10.648M
		Slapnicar [8]	MIMIC III	510	700h	PPG, ECG, ABP	Raw signal	9.43	6.88	-	3.523M

5 おわりに

本稿では、PPG 信号のみを用いて、ドメイン敵対的学習とキャリブレーションを用いて、データの個人差を考慮した高精度な RDAE を提案した。ドメイン敵対的学習とキャリブレーションにより、予測精度とロバスト性が改善され、従来法と比較してパラメータ数の少ないモデルを開発できたことを確認した。

参考文献

- [1] G. Thambiraj, U. Gandhi, V. Devanand, M. Umapathy, Non-invasive cuffless blood pressure estimation using pulse transit time, Womersley number, and photoplethysmogram intensity ratio, *Physiol. Meas.* 40 (2019)
- [2] I. Sharifi, S. Goudarzi, M.B. Khodabakhshi, A novel dynamical approach in continuous cuffless blood pressure estimation based on ECG and PPG signals, *Artif. Intell. Med.* 97 (2018)
- [3] Q. Zhu, X. Tian, C.W. Wong, M. Wu, ECG reconstruction via PPG: A pilot study, in: 2019 IEEE EMBS International Conference on Biomedical and Health Informatics, BHI, IEEE, 2019, pp. 1-4
- [4] J. Allen, Photoplethysmography and its application in clinical physiological measurement, *Physiol. Meas.* 28 (2007) R1-39
- [5] G. Martínez, N. Howard, D. Abbott, K. Lim, R. Ward, M. Elgendi, Can photoplethysmography replace arterial blood pressure in the assessment of blood pressure? *J. Clin. Med.* 7 (2018) 316
- [6] X.M. Xing, M.S. Sun, Optical blood pressure estimation with photoplethysmography and FFT-based neural networks, *Biomed. Opt. Express* 7 (2016) 3007-3020
- [7] H. Eom, D. Lee, S. Han, Y. Hariyani, Y. Lim, I. Sohn, K. Park, C. Park, End-to-End deep learning architecture for continuous blood pressure estimation using attention mechanism, *Sensors* 20 (2020) 2338
- [8] N. Ibtehaz, M.S. Rahman, PPG2ABP: Translating photoplethysmogram (PPG) signals to arterial blood pressure (ABP) waveforms using fully convolutional neural networks, 2020, arXiv:arXiv:2005.01669.
- [9] O. Ronneberger, P. Fischer, T. Brox, U-Net: Convolutional networks for biomedical image segmentation, in: *International Conference on Medical Image Computing and Computer-Assisted Intervention*, Vol. 9351, Springer, 2015, pp. 234-241 using a spectro-temporal deep neural network, *Sensors* 19 (2019) 3420
- [10] <https://archive.ics.uci.edu/ml/datasets/Cuff-Less+Blood+Pressure+Estimation>