

5.5 活性化関数レイヤの実装

この節では、計算グラフの考え方をニューラルネットワークに適用する。ここでは、ニューラルネットワークを構成する「層（レイヤ）」をひとつのクラスとして実装する。まずは、活性化関数である ReLU と Sigmoid レイヤを実装する。

5.5.1 ReLU レイヤ

活性化関数として使われる ReLU(Rectified Linear Unit) は、次の式 (5.7) で表された。

$$y = \begin{cases} x & (x > 0) \\ 0 & (x \leq 0) \end{cases} \quad (5.7)$$

式 (5.7) から、 x に関する y の微分は式 (5.8) のように求められる。計算グラフで表すと、図 5-18 のように書くことができる。

$$\frac{\partial y}{\partial x} = \begin{cases} 1 & (x > 0) \\ 0 & (x \leq 0) \end{cases} \quad (5.8)$$




図 5-18 ReLU レイヤの計算グラフ

では、この ReLU レイヤの実装を行う。実装は、以下のソースコードのようになる。

ソースコード 1 ReLU

```
1 class Relu:
2     def __init__(self):
3         self.mask = None
4
5     def forward(self, x):
6         self.mask = (x <= 0)
7         out = x.copy()
8         out[self.mask] = 0
9
10        return out
```

```

11
12     def backward(self, dout):
13         dout[self.mask] = 0
14         dx = dout
15
16         return dx

```

Relu クラスは、mask というインスタンス変数を持つ。mask は、True/False からなる Numpy 配列で、順伝播の入力である x の要素で 0 以下の場所を True、0 より大きい要素を False として保持する。

ソースコード 2 mask の例

```

1 >>> x = np.array([[1.0, -0.5], [-2.0, 3.0]])
2 >>> print(x)
3 [[ 1. -0.5]
4  [-2.  3. ]]
5 >>> mask = (x <= 0)
6 >>> print(mask)
7 [[False True]
8  [ True False]]

```

図 5-18 に示すように、順伝播の入力が 0 以下ならば、逆伝播の値は 0 になるため、逆伝播では、順伝播時に保持した mask を用いて、上流から伝播された dout に対して、mask の要素が True の場所を 0 に設定する。

5.5.2 Sigmoid レイヤ

続いて、シグモイド関数を実装する。シグモイド関数を計算グラフで表すと、次の図 5-19 のようになる。




図 5-19 Sigmoid レイヤの計算グラフ（順伝播のみ）

図 5-19 では「 \times 」と「 $+$ 」ノードの他に、「 \exp 」と「 $/$ 」ノードが新しく登場している。「 \exp 」ノードは $y = \exp(x)$ の計算を行い、「 $/$ 」ノードは、 $y = \frac{1}{x}$ の計算をする。Sigmoid レイヤの逆伝播の計算の流れをまとめると、図 5-20 のような計算グラフとなる。




図 5-20 Sigmoid レイヤの計算グラフ

図 5-20 の結果から逆伝播の出力は、 $\frac{\partial L}{\partial y} y^2 \exp(-x)$ となり、この値が下流にあるノードに伝播していく。ここで $\frac{\partial L}{\partial y} y^2 \exp(-x)$ という値が順伝播の入力 x と出力 y だけから計算できる点に注目すると、次の図 5-21 のようなグループ化した「sigmoid」ノードとして書くことができる。

そして、 $\frac{\partial L}{\partial y} y^2 \exp(-x)$ は、さらに次のように整理して書くことができる。

$$\begin{aligned}
 \frac{\partial L}{\partial y} y^2 \exp(-x) &= \frac{\partial L}{\partial y} \frac{1}{(1 + \exp(-x))^2} \exp(-x) \\
 &= \frac{\partial L}{\partial y} \frac{1}{1 + \exp(-x)} \frac{\exp(-x)}{1 + \exp(-x)} \\
 &= \frac{\partial L}{\partial y} y(1 - y)
 \end{aligned} \tag{5.12}$$

そのため、図 5-21 で表される Sigmoid レイヤの逆伝播は、順伝播の出力だけから計算することが出来る。




図 5-21 Sigmoid レイヤの計算グラフ：順伝播の出力 y によって、逆伝播の計算を行うことができる

ソースコード 3 Sigmoid

```

1 class Sigmoid:
2     def __init__(self):
3         self.out = None
4     def forward(self, x):
5         out = 1 / (1 + np.exp(-x))
6         self.out = out
7
8         return out
9
10    def backward(self, dout):

```

```
11         dx = dout * (1.0 - self.out) * self.out
12
13     return dx
```

この実装では、順伝播時に出力をインスタンス変数の `out` に保持している。そして逆伝播時に、その `out` 変数を使って計算を行う。